



---

**PRA-SKRIPSI**

**SISTEM PERAMALAN MULTI-HORIZON  
KEKERINGAN LAHAN PERTANIAN SENTRA  
PADI JAWA TIMUR BERBASIS SPEI  
MENGUNAKAN TFT**

**NAUFAL TAFINDYA PUTRA**  
NPM 22081010193

**DOSEN PEMBIMBING**

Dr. Faisal Muttaqin, S.Kom, M.T  
Andreas Nugroho Sihananto, S.Kom., M.Kom.

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI INFORMATIKA  
SURABAYA  
2026**

## ABSTRAK

Nama Mahasiswa / NPM : Naufal Tafindya Putra / 22081010193  
Judul Skripsi : Sistem Peramalan Multi-Horizon Kekeringan Lahan  
Pertanian Sentra Padi Jawa Timur Berbasis SPEI  
Menggunakan TFT  
Dosen Pembimbing : 1. Dr. Faisal Muttaqin, S.Kom, M.T  
2. Andreas Nugroho Sihananto, S.Kom., M.Kom.

[DRAFT]

Kekeringan merupakan fenomena iklim yang dapat menimbulkan dampak signifikan terhadap sektor pertanian dan ketahanan pangan. Pemantauan kondisi kekeringan umumnya dilakukan menggunakan indeks kekeringan seperti Standardized Precipitation Evapotranspiration Index (SPEI). Namun, sebagian besar pemanfaatan indeks ini masih bersifat deskriptif dan retrospektif sehingga belum sepenuhnya mendukung kebutuhan peringatan dini melalui peramalan kondisi kekeringan di masa mendatang. Penelitian ini bertujuan untuk mengembangkan dan mengevaluasi model peramalan SPEI-3 secara multi-horizon menggunakan metode Temporal Fusion Transformer (TFT) pada lima sentra padi di Provinsi Jawa Timur, yaitu Bojonegoro, Lamongan, Nganjuk, Ngawi, dan Tuban. Data yang digunakan berupa data historis iklim periode 2005–2025 yang mencakup variabel presipitasi, suhu, evapotranspirasi potensial, kelembaban tanah, serta informasi temporal. Model TFT digunakan untuk menghasilkan prediksi probabilistik berbasis quantile (P10, P50, P90) hingga horizon 30 hari ke depan. Evaluasi model dilakukan menggunakan metrik RMSE, MAE, koefisien determinasi ( $R^2$ ), dan korelasi Pearson, serta analisis interpretabilitas melalui mekanisme variable selection network dan attention weights.

**Kata kunci:** Deep learning, kekeringan pertanian, peramalan multi-horizon, peringatan dini kekeringan, SPEI-3, Temporal Fusion Transformer

## ABSTRACT

Nama Mahasiswa / NPM : Naufal Tafindya Putra / 22081010193  
Judul Skripsi : Sistem Peramalan Multi-Horizon Kekeringan Lahan  
Pertanian Sentra Padi Jawa Timur Berbasis SPEI  
Menggunakan TFT  
Dosen Pembimbing : 1. Dr. Faisal Muttaqin, S.Kom, M.T  
2. Andreas Nugroho Sihananto, S.Kom., M.Kom.

[DRAFT]

Drought is a climate phenomenon that can significantly affect agricultural productivity and food security. Monitoring drought conditions is commonly performed using drought indices such as the Standardized Precipitation Evapotranspiration Index (SPEI). However, most applications of this index remain descriptive and retrospective, limiting its ability to support early warning systems through forecasting future drought conditions. This study aims to develop and evaluate a multi-horizon forecasting model for SPEI-3 using the Temporal Fusion Transformer (TFT) in five major rice-producing regions of East Java, Indonesia: Bojonegoro, Lamongan, Nganjuk, Ngawi, and Tuban. The dataset consists of historical climate data from 2005 to 2025, including precipitation, temperature, potential evapotranspiration, soil moisture, and temporal features. The TFT model is employed to generate probabilistic forecasts based on quantiles (P10, P50, P90) with a prediction horizon of up to 30 days. Model performance is evaluated using RMSE, MAE, coefficient of determination ( $R^2$ ), and Pearson correlation, along with interpretability analysis through the variable selection network and attention mechanisms.

**Keywords:** Agricultural drought, deep learning, drought early warning system, multi-horizon forecasting, SPEI-3, Temporal Fusion Transformer

## DAFTAR ISI

|                                                                                              |     |
|----------------------------------------------------------------------------------------------|-----|
| DAFTAR ISI.....                                                                              | iv  |
| DAFTAR GAMBAR .....                                                                          | vi  |
| DAFTAR TABEL .....                                                                           | vii |
| BAB I PENDAHULUAN.....                                                                       | 1   |
| 1.1 Latar Belakang .....                                                                     | 1   |
| 1.2 Rumusan Masalah .....                                                                    | 4   |
| 1.3 Tujuan Penelitian.....                                                                   | 5   |
| 1.4 Manfaat Penelitian.....                                                                  | 6   |
| 1.5 Batasan Masalah.....                                                                     | 7   |
| BAB II TINJAUAN PUSTAKA.....                                                                 | 9   |
| 2.1 Penelitian Terdahulu.....                                                                | 9   |
| 2.2 Landasan Teori .....                                                                     | 17  |
| 2.2.1 Kekeringan Pertanian.....                                                              | 17  |
| 2.2.2 Indeks Kekeringan dan Standardized Precipitation Evapotranspiration Index (SPEI) ..... | 19  |
| 2.2.2.1 Konsep dan Keunggulan SPEI .....                                                     | 19  |
| 2.2.2.2 Prinsip Dasar Perhitungan SPEI.....                                                  | 20  |
| 2.2.2.3 Peran Evapotranspirasi dalam Analisis Kekeringan .....                               | 20  |
| 2.2.2.4 Alasan Teoretis Pemilihan SPEI-3 .....                                               | 21  |
| 2.2.2.5 Keterbatasan SPEI.....                                                               | 21  |
| 2.2.3 Peramalan Time Series Iklim.....                                                       | 22  |
| 2.2.3.1 Karakteristik Time Series Iklim dan Tantangan Peramalan.....                         | 22  |
| 2.2.3.2 Keterbatasan Metode Statistik Tradisional.....                                       | 23  |
| 2.2.3.3 Perkembangan Pendekatan Machine Learning dan Deep Learning. ....                     | 23  |
| 2.2.4 Multi-Horizon Time Series Forecasting .....                                            | 24  |
| 2.2.4.1 Definisi dan Skema Multi-Horizon Forecasting.....                                    | 24  |
| 2.2.4.2 Keunggulan dan Tantangan Pendekatan Multi-Horizon .....                              | 25  |
| 2.2.4.3 Relevansi Multi-Horizon untuk Peringatan Dini Kekeringan Pertanian .....             | 26  |
| 2.2.5 Peramalan Probabilistik dan Ketidakpastian Prediksi .....                              | 26  |
| 2.2.5.1 Perbandingan Deterministic dan Probabilistic Forecast.....                           | 26  |
| 2.2.5.2 Quantile Forecasting dan Prediction Interval .....                                   | 27  |
| 2.2.5.3 Pentingnya Kalibrasi (Global vs Per Lokasi) .....                                    | 27  |

|                |                                                                                                |    |
|----------------|------------------------------------------------------------------------------------------------|----|
| 2.2.6          | Temporal Fusion Transformer (TFT) .....                                                        | 28 |
| 2.2.6.1        | Tujuan Desain dan Keunggulan TFT .....                                                         | 28 |
| 2.2.6.2        | Arsitektur Utama Temporal Fusion Transformer .....                                             | 29 |
| 2.2.6.3        | Penanganan Berbagai Jenis Input, Multi-Horizon, Quantile<br>Output, dan Interpretabilitas..... | 30 |
| 2.2.7          | Pengembangan Web Visualisasi Data Menggunakan Vue.js dan<br>FastAPI.....                       | 30 |
| 2.3            | Analisis Celah Penelitian.....                                                                 | 32 |
| 2.3.1          | Sintesis Temuan Penelitian Terdahulu .....                                                     | 32 |
| 2.3.2          | Celah Metodologis.....                                                                         | 33 |
| 2.3.3          | Celah Operasional dan Kontekstual.....                                                         | 33 |
| 2.3.4          | Posisi dan Kontribusi Penelitian .....                                                         | 33 |
| BAB III        | METODE PENELITIAN .....                                                                        | 35 |
| 3.1            | Tahapan Penelitian .....                                                                       | 35 |
| 3.2            | Pengumpulan Data .....                                                                         | 36 |
| 3.3            | Preprocessing Data .....                                                                       | 39 |
| 3.4            | Komputasi Indeks SPEI.....                                                                     | 43 |
| 3.5            | Pembentukan Dataset Time Series .....                                                          | 46 |
| 3.6            | Perancangan Model Temporal Fusion Transformer.....                                             | 49 |
| 3.7            | Pelatihan dan Validasi Model.....                                                              | 53 |
| 3.8            | Peramalan Multi-Horizon.....                                                                   | 55 |
| 3.9            | Evaluasi Model.....                                                                            | 57 |
| 3.10           | Analisis Interpretabilitas Model .....                                                         | 62 |
| 3.11           | Perancangan Web Visualisasi Hasil Peramalan .....                                              | 63 |
| DAFTAR PUSTAKA | .....                                                                                          | 66 |

## DAFTAR GAMBAR

|            |                                                                            |    |
|------------|----------------------------------------------------------------------------|----|
| Gambar 2.1 | Ilustrasi Peramalan Multi-Horizon [24], [30] .....                         | 25 |
| Gambar 2.2 | Arsitektur Temporal Fusion Transformer (TFT) [24], [30] .....              | 29 |
| Gambar 3.1 | Alur Tahapan Penelitian.....                                               | 35 |
| Gambar 3.2 | Flowchart Preprocessing Data .....                                         | 40 |
| Gambar 3.3 | Visualisasi Lima Node Terpilih pada Setiap Wilayah Penelitian ....         | 42 |
| Gambar 3.4 | Struktur Encoder dan Prediction Window pada Dataset Time Series .<br>..... | 47 |
| Gambar 3.5 | Skema Pembagian Dataset Secara Kronologis .....                            | 49 |
| Gambar 3.6 | Alur Proses Pelatihan .....                                                | 54 |
| Gambar 3.7 | Mockup Web Visualisasi .....                                               | 64 |

## DAFTAR TABEL

|           |                                                            |    |
|-----------|------------------------------------------------------------|----|
| Tabel 2.1 | Klasifikasi dan Kategori Indeks Kekeringan [13], [15]..... | 19 |
| Tabel 3.1 | Koordinat Pusat Wilayah Penelitian .....                   | 37 |
| Tabel 3.2 | Parameter Penelitian .....                                 | 37 |
| Tabel 3.3 | Kategori Indeks SPEI.....                                  | 44 |
| Tabel 3.4 | Contoh Komputasi Nilai SPEI.....                           | 45 |
| Tabel 3.5 | Konfigurasi Model Temporal Fusion Transformer .....        | 51 |
| Tabel 3.6 | Skenario Evaluasi .....                                    | 57 |

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Kekeringan merupakan fenomena iklim yang memiliki dampak langsung dan signifikan terhadap produktivitas pertanian, ketahanan pangan, serta stabilitas sosial-ekonomi di berbagai wilayah dunia. Peristiwa kekeringan yang terjadi secara tiba-tiba dan intens, seperti flash drought di Rusia pada 2010, menyebabkan penurunan hasil panen gandum hingga lebih dari 70% di wilayah penghasil utama, yang kemudian berdampak pada penurunan produksi global dan kenaikan harga pangan secara drastis, memicu kemiskinan dan kerusuhan sosial di beberapa negara [1]. Perubahan iklim global semakin memperparah kondisi ini dengan meningkatkan frekuensi, durasi, dan intensitas kekeringan, sehingga ancaman terhadap sektor pertanian dan ketahanan pangan menjadi semakin nyata dan mendesak untuk diatasi [2], [3]. Kekeringan pertanian, yang ditandai oleh defisit kelembaban tanah dan evapotranspirasi, secara langsung mengganggu pertumbuhan tanaman dan hasil panen, seperti yang terlihat pada penurunan produksi jagung dan sorgum di Afrika Selatan selama tahun-tahun kekeringan ekstrem [4]. Dampak sosial-ekonomi dari kekeringan juga meliputi ketidakstabilan sosial dan kebutuhan intervensi pemerintah untuk menjaga keseimbangan pasokan dan permintaan pangan, sebagaimana tercatat dalam studi perbandingan antara Jerman dan wilayah Jing-Jin-Ji di China [5]. Oleh karena itu, pengembangan sistem peringatan dini (early warning system) yang efektif sangat penting dalam sektor pertanian untuk memantau dan meramalkan kondisi kekeringan secara real-time, memungkinkan pengambilan keputusan yang tepat waktu guna mengurangi risiko kerugian produksi dan menjaga ketahanan pangan [6], [7].

Indeks kekeringan berperan penting sebagai alat kuantitatif dalam memantau kondisi kekeringan secara sistematis dan objektif. Di antara berbagai indeks yang ada, *Standardized Precipitation Evapotranspiration Index* (SPEI) menonjol karena kemampuannya menggabungkan data presipitasi dan evapotranspirasi, sehingga lebih sensitif terhadap perubahan suhu dan dinamika iklim dibandingkan indeks lain seperti *Standardized Precipitation Index* (SPI) dan *Palmer Drought Severity Index*



(PDSI) [8], [9]. SPEI mampu menangkap pengaruh suhu yang mempengaruhi evaporasi dan kebutuhan air tanaman, yang sangat relevan dalam konteks perubahan iklim yang meningkatkan stres kekeringan pada tanaman. Penggunaan SPEI dengan skala waktu tiga bulan (SPEI-3) sangat sesuai untuk memantau kekeringan pertanian musiman karena mencerminkan kondisi kelembaban tanah dan ketersediaan air yang mempengaruhi fase kritis pertumbuhan tanaman [10], [11]. Studi di berbagai wilayah, termasuk China dan Argentina, menunjukkan korelasi kuat antara SPEI dan indikator hasil panen, menegaskan efektivitas SPEI dalam menilai dampak kekeringan pada sektor pertanian [8], [10]. Meski demikian, efektivitas SPEI dapat bervariasi menurut wilayah dan musim, sehingga evaluasi lokal tetap diperlukan sebelum penerapan langsung [8]. Dengan demikian, SPEI merupakan alat yang sangat berguna dalam monitoring kekeringan pertanian dan mendukung pengembangan sistem peringatan dini yang adaptif terhadap perubahan iklim [9], [11].

Mayoritas penggunaan SPEI dalam monitoring kekeringan bersifat deskriptif dan retrospektif, sehingga lebih fokus pada pemantauan kondisi saat ini daripada peramalan di masa depan. Model statistik tradisional seperti ARIMA dan regresi sering mengasumsikan linearitas, sehingga kesulitan menangkap dinamika non-linear yang kompleks dalam data kekeringan, yang menyebabkan penurunan performa terutama pada peramalan dengan horizon waktu yang lebih panjang [12], [13]. Ketidakpastian dalam prediksi iklim juga menjadi tantangan besar, karena variabilitas iklim yang tinggi dan data yang nonstasioner serta berisik mempersulit akurasi model peramalan [14]. Studi menunjukkan bahwa model berbasis filter Kalman dan jaringan saraf seperti LSTM dan GRU dapat meningkatkan akurasi prediksi SPEI, terutama pada skala waktu yang lebih panjang, namun kestabilan dan presisi pada skala pendek masih menjadi kendala [13], [15]. Pendekatan hybrid yang menggabungkan metode statistik dan deep learning, seperti ARIMA-LSTM, menunjukkan peningkatan signifikan dalam akurasi prediksi dibandingkan model tunggal, terutama untuk peramalan jangka panjang [12]. Meski demikian, penurunan akurasi dengan meningkatnya lead time dan kompleksitas spasial-temporal iklim menuntut pengembangan model yang lebih adaptif dan mampu mengatasi ketidakpastian secara efektif [16], [17].

Pendekatan modern dalam monitoring dan peramalan kekeringan semakin mengandalkan *machine learning* (ML) dan *deep learning* (DL) yang mampu menangani data time series iklim dengan pola non-linear dan multivariat, seperti model LSTM, CNN, dan Transformer. Model-model ini menunjukkan keunggulan dalam akurasi prediksi dan kemampuan menangkap kompleksitas dinamika kekeringan yang sulit dijangkau oleh metode statistik tradisional [18], [19], [20]. Namun, masalah utama yang muncul adalah sifat black-box dari model-model ini, yang menyebabkan rendahnya kepercayaan pengguna, terutama para pemangku kepentingan di sektor pertanian yang membutuhkan interpretabilitas untuk pengambilan keputusan [21], [22]. Oleh karena itu, kebutuhan akan model yang tidak hanya akurat tetapi juga mampu memodelkan ketidakpastian dan memberikan interpretasi yang jelas menjadi sangat penting untuk meningkatkan adopsi teknologi ini. Beberapa studi mengusulkan pendekatan hybrid yang menggabungkan ML/DL dengan teknik interpretabilitas seperti analisis fitur penting dan metode explainable AI untuk menyeimbangkan trade-off antara akurasi dan transparansi [19], [21]. Dengan demikian, pengembangan model yang dapat dipercaya dan mudah dipahami oleh pengguna akhir menjadi fokus utama dalam riset peramalan kekeringan berbasis data-driven saat ini [22], [23].

Penelitian yang secara simultan menggabungkan prediksi SPEI multi-horizon, prediksi probabilistik, dan mekanisme interpretabilitas masih sangat minim, terutama yang diterapkan dalam konteks pertanian regional Indonesia. Kesenjangan ini menciptakan tantangan besar dalam memenuhi kebutuhan operasional untuk pengambilan keputusan dini yang akurat dan dapat dipercaya oleh para pemangku kepentingan. Studi terkini menunjukkan bahwa model seperti *Temporal Fusion Transformer* (TFT) mampu melakukan multi-horizon forecasting dengan interpretabilitas yang lebih baik melalui mekanisme self-attention, namun penerapannya pada SPEI dan konteks lokal masih terbatas [24]. Selain itu, pendekatan probabilistik dalam peramalan SPEI yang mengakomodasi ketidakpastian iklim juga masih jarang dikombinasikan dengan model yang mudah diinterpretasikan, padahal hal ini penting untuk kalibrasi dan keandalan prediksi [25], [26]. Kebutuhan akan model yang mempertimbangkan heterogenitas spasial

sangat penting mengingat variasi iklim dan kondisi pertanian yang berbeda-beda di Indonesia, sehingga pendekatan berbasis lokasi dapat meningkatkan relevansi dan akurasi prediksi [27]. Oleh karena itu, pengembangan model SPEI forecasting yang multi-horizon, probabilistik, dan interpretatif dengan fokus pada konteks regional Indonesia merupakan gap riset yang signifikan dan mendesak untuk diisi [15], [28], [29].

*Temporal Fusion Transformer* (TFT) merupakan pendekatan yang sangat relevan untuk forecasting SPEI karena mendukung prediksi multi-horizon dengan keluaran probabilistik berupa quantile, sekaligus menyediakan interpretabilitas melalui mekanisme seleksi variabel dan self-attention yang transparan terhadap dinamika temporal [24]. Studi kasus pada sentra padi di Jawa Timur sangat tepat karena kebutuhan prediksi kekeringan yang akurat dan dapat diandalkan sangat krusial untuk mendukung keputusan pertanian di wilayah dengan heterogenitas spasial tinggi. Kontribusi penelitian ini bersifat empiris dengan evaluasi performa model TFT pada data lokal, metodologis melalui kalibrasi model per lokasi untuk menangani variasi spasial, serta aplikatif dalam mendeteksi dan memitigasi risiko kekeringan secara dini. Literatur menunjukkan bahwa TFT unggul dibandingkan model deep learning lain dalam multi-horizon forecasting dan interpretabilitas, sehingga memberikan nilai tambah signifikan untuk sistem pendukung keputusan berbasis data iklim [30], [31]. Dengan mengintegrasikan kemampuan probabilistik dan interpretatif, penelitian ini mengisi gap penting dalam forecasting SPEI yang selama ini jarang diakomodasi secara bersamaan, khususnya dalam konteks pertanian regional Indonesia. Pendekatan ini diharapkan dapat meningkatkan kepercayaan pengguna dan efektivitas pengambilan keputusan dalam mitigasi dampak kekeringan.

## **1.2 Rumusan Masalah**

Berdasarkan latar belakang yang telah diuraikan, permasalahan penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana kinerja model Temporal Fusion Transformer (TFT) dalam melakukan peramalan indeks kekeringan SPEI-3 secara multi-horizon pada sentra padi di Jawa Timur?

2. Sejauh mana pendekatan peramalan probabilistik berbasis *quantile* pada model TFT, termasuk kalibrasi per lokasi, mampu merepresentasikan ketidakpastian dan meningkatkan reliabilitas prediksi SPEI-3 pada berbagai horizon waktu?
3. Bagaimana perubahan atau degradasi kinerja peramalan SPEI-3 yang dihasilkan model TFT seiring dengan peningkatan horizon waktu prediksi?
4. Variabel iklim dan informasi temporal apa yang paling berpengaruh terhadap hasil peramalan SPEI-3, serta sejauh mana hasil peramalan tersebut dapat dimanfaatkan untuk mendeteksi kejadian kekeringan parah di sentra padi Jawa Timur?
5. Bagaimana merancang dan mengimplementasikan website dashboard untuk menyajikan hasil peramalan SPEI-3 secara informatif dan mendukung interpretasi serta pemanfaatan hasil prediksi dalam pemantauan kekeringan pertanian?

### **1.3 Tujuan Penelitian**

Tujuan umum dari penelitian ini adalah mengembangkan dan mengevaluasi model Temporal Fusion Transformer (TFT) untuk peramalan indeks kekeringan SPEI-3 secara multi-horizon pada sentra padi di Jawa Timur, guna mendukung pemantauan dan deteksi dini kekeringan pertanian berbasis data iklim.

Untuk mencapai tujuan umum tersebut, penelitian ini memiliki tujuan khusus sebagai berikut:

1. Mengevaluasi kinerja model Temporal Fusion Transformer (TFT) dalam meramalkan SPEI-3 secara multi-horizon pada sentra padi di Jawa Timur berdasarkan metrik kuantitatif seperti RMSE, MAE, koefisien determinasi ( $R^2$ ), dan korelasi.
2. Menganalisis kemampuan model TFT dalam menghasilkan prediksi probabilistik berbasis *quantile* serta menilai efektivitas pendekatan kalibrasi per lokasi dalam merepresentasikan ketidakpastian dan meningkatkan reliabilitas prediksi SPEI-3.
3. Menganalisis degradasi kinerja peramalan SPEI-3 terhadap peningkatan horizon waktu prediksi untuk memahami stabilitas dan keterbatasan model dalam peramalan jangka pendek hingga menengah.

4. Mengidentifikasi variabel iklim dan informasi temporal yang paling berpengaruh terhadap hasil peramalan SPEI-3 berdasarkan mekanisme interpretabilitas model TFT, serta mengevaluasi pemanfaatan hasil peramalan tersebut dalam mendeteksi kejadian kekeringan parah.
5. Merancang dan mengimplementasikan website dashboard untuk menyajikan hasil peramalan SPEI-3 secara visual dan informatif guna mendukung interpretasi model dan pemantauan kondisi kekeringan pertanian.

#### **1.4 Manfaat Penelitian**

Penelitian ini diharapkan dapat memberikan kontribusi baik secara teoritis maupun praktis melalui hasil yang diperoleh dari setiap tujuan khusus yang telah dirumuskan. Secara umum, manfaat penelitian ini dapat dijelaskan sebagai berikut:

1. Memberikan gambaran empiris mengenai kinerja model Temporal Fusion Transformer (TFT) dalam meramalkan indeks kekeringan SPEI-3 secara multi-horizon pada sentra padi di Jawa Timur, sehingga dapat menjadi acuan dalam pemilihan metode peramalan yang sesuai untuk data iklim multivariat.
2. Menyediakan pendekatan peramalan probabilistik yang mampu merepresentasikan ketidakpastian prediksi melalui quantile, serta menunjukkan efektivitas kalibrasi per lokasi dalam meningkatkan reliabilitas hasil peramalan pada kondisi iklim yang heterogen.
3. Memberikan pemahaman mengenai pola degradasi kinerja model terhadap peningkatan horizon waktu prediksi, sehingga dapat membantu dalam menentukan batas penggunaan model yang optimal untuk kebutuhan peramalan jangka pendek hingga menengah.
4. Menghasilkan informasi terkait variabel iklim dan faktor temporal yang paling berpengaruh terhadap prediksi kekeringan, serta mendukung pemanfaatan hasil peramalan dalam mendeteksi kejadian kekeringan parah secara lebih dini.
5. Menyediakan website dashboard yang menyajikan hasil peramalan SPEI-3 secara visual dan informatif, sehingga dapat memudahkan interpretasi hasil model serta mendukung pemantauan kondisi kekeringan pertanian secara lebih terstruktur.

## 1.5 Batasan Masalah

Untuk menjaga fokus penelitian dan memastikan hasil yang diperoleh tetap valid serta dapat dipertanggungjawabkan secara ilmiah, penelitian ini dibatasi pada beberapa aspek sebagai berikut:

1. Objek penelitian dibatasi pada peramalan indeks kekeringan SPEI-3 (skala tiga bulan). Batasan ini ditetapkan karena SPEI-3 merepresentasikan kondisi kekeringan pertanian musiman yang relevan terhadap fase pertumbuhan tanaman padi, sehingga sesuai dengan tujuan penelitian. Skala SPEI lain tidak dibahas untuk menjaga konsistensi analisis dan menghindari perluasan ruang lingkup yang berlebihan.
2. Wilayah studi dibatasi pada lima sentra padi di Provinsi Jawa Timur, yaitu Bojonegoro, Lamongan, Nganjuk, Ngawi, dan Tuban. Pemilihan wilayah ini didasarkan pada perannya sebagai sentra produksi padi dengan karakteristik iklim dan kondisi pertanian yang beragam. Penelitian ini tidak bertujuan untuk melakukan generalisasi hasil ke wilayah lain di Indonesia atau skala nasional.
3. Data yang digunakan terbatas pada data historis periode 2005–2025 dengan resolusi temporal harian. Batasan ini mengikuti ketersediaan dan konsistensi data iklim yang digunakan dalam penelitian. Pengaruh perubahan kualitas data, ketidaklengkapan observasi, serta skenario iklim masa depan di luar periode tersebut tidak dianalisis.
4. Metode peramalan difokuskan pada penggunaan model *Temporal Fusion Transformer* (TFT) tanpa melakukan perbandingan menyeluruh dengan berbagai model statistik atau deep learning lainnya. Penelitian ini bertujuan mengevaluasi kinerja dan karakteristik TFT secara mendalam, bukan untuk menentukan model terbaik secara universal. Oleh karena itu, studi komparatif lintas model tidak menjadi fokus utama.
5. Peramalan dilakukan secara multi-horizon hingga 30 hari ke depan dengan pendekatan probabilistik berbasis quantile. Horizon peramalan yang lebih panjang dari 30 hari tidak dibahas karena potensi penurunan akurasi yang signifikan dan keterbatasan reliabilitas prediksi dalam konteks pengambilan keputusan operasional jangka pendek hingga menengah di sektor pertanian.

6. Analisis interpretabilitas dibatasi pada mekanisme bawaan model TFT, yaitu variable selection network dan temporal attention, tanpa melakukan analisis kausal atau inferensi sebab-akibat. Interpretabilitas dalam penelitian ini dipahami sebagai upaya memahami kontribusi relatif variabel dan dinamika temporal terhadap prediksi model, bukan untuk menyimpulkan hubungan kausal antarvariabel iklim.
7. Deteksi kejadian kekeringan dilakukan berdasarkan ambang batas SPEI  $< -1,5$  dan diformulasikan sebagai masalah klasifikasi biner. Penelitian ini tidak membahas variasi ambang batas, analisis tingkat keparahan yang lebih rinci, maupun implementasi sistem peringatan dini secara operasional.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **2.1 Penelitian Terdahulu**

Penelitian-penelitian yang sudah dilakukan peneliti sebelumnya yang terkait dengan penelitian yang akan dilakukan adalah sebagai berikut.

1. Penelitian “Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting” oleh Lim et al. (2021) [24].

Penelitian oleh Lim et al. (2021) mengusulkan model *Temporal Fusion Transformer* (TFT) untuk peramalan deret waktu multi-horizon yang tidak hanya akurat tetapi juga interpretable. Model ini menggabungkan arsitektur attention mechanism dengan komponen gating dan variable selection untuk menangani data statis, historis, dan variabel masa depan secara simultan. Keunggulan utama TFT terletak pada kemampuannya memilih fitur relevan secara adaptif serta memberikan interpretasi kontribusi variabel melalui attention weights. Model ini diuji pada berbagai dataset dan menunjukkan performa yang lebih baik dibanding metode konvensional seperti LSTM dan model statistik, terutama dalam menangkap dependensi jangka panjang dan hubungan kompleks antar variabel. Selain itu, TFT mampu mengatasi permasalahan overfitting melalui mekanisme gating yang menyaring informasi yang tidak relevan. Kontribusi penting penelitian ini adalah menyediakan model deep learning yang tidak hanya berorientasi pada akurasi prediksi, tetapi juga transparansi, sehingga lebih sesuai untuk aplikasi kritis seperti energi, keuangan, dan iklim. Namun, kompleksitas arsitektur dan kebutuhan komputasi yang tinggi menjadi keterbatasan utama dalam implementasinya.

2. Penelitian “Application of a Hybrid ARIMA–LSTM Model Based on the SPEI for Drought Forecasting” oleh Xu et al. (2021) [12].

Penelitian ini mengembangkan model hybrid ARIMA-LSTM untuk meningkatkan akurasi prediksi kekeringan berbasis indeks SPEI. ARIMA digunakan untuk menangkap pola linear, sedangkan LSTM menangani komponen nonlinear dari residual. Data yang digunakan berasal dari 613 stasiun meteorologi di China (1980–2019) dengan skala SPEI multibulan (1–24 bulan). Evaluasi menggunakan MSE, RMSE, MAE, dan NSE menunjukkan bahwa



model hybrid secara konsisten mengungguli model tunggal maupun hybrid lain, terutama pada skala waktu menengah hingga panjang (SPEI6–SPEI24), dengan nilai NSE hingga 0.93. Hasil ini menunjukkan bahwa kombinasi pendekatan linear dan nonlinear lebih efektif dalam menangkap kompleksitas data hidrometeorologi. Namun, akurasi menurun pada skala pendek (SPEI1) dan saat lead time diperpanjang, menunjukkan keterbatasan dalam prediksi jangka sangat pendek. Secara keseluruhan, penelitian ini menegaskan bahwa model hybrid merupakan pendekatan yang lebih robust untuk peramalan kekeringan, meskipun memiliki kompleksitas dan kebutuhan komputasi lebih tinggi dibanding model tunggal.

3. Penelitian “Modeling Short-Term Drought for SPEI in Mainland China Using the XGBoost Model” oleh Zeng et al. (2025) [14].

Penelitian oleh Zeng et al. (2025) mengembangkan kerangka prediksi kekeringan jangka pendek berbasis XGBoost dengan optimalisasi lanjutan menggunakan CPSO (Coding Particle Swarm Optimization) untuk meningkatkan akurasi prediksi indeks SPEI. Studi ini membandingkan tiga model, yaitu XGBoost dasar, XGBoost dengan seleksi fitur berbasis korelasi Pearson, dan CPSO-XGBoost yang menggabungkan optimasi parameter serta seleksi fitur secara simultan. Hasil penelitian menunjukkan bahwa performa model meningkat seiring bertambahnya skala waktu, dengan akurasi rendah pada SPEI-1 ( $R^2$  sekitar 0.32–0.41) dan mencapai performa optimal pada SPEI-12 ( $R^2$  hingga 0.90). Model CPSO-XGBoost secara konsisten memberikan hasil terbaik dengan penurunan error hingga lebih dari 20% dibanding model lainnya. Selain itu, performa model lebih tinggi pada wilayah lembab dibanding wilayah kering, yang memiliki variabilitas iklim lebih kompleks. Penelitian ini juga menunjukkan bahwa integrasi optimasi parameter dan seleksi fitur mampu meningkatkan kemampuan model dalam menangkap hubungan nonlinear antara variabel atmosfer dan daratan. Namun, keterbatasan tetap ditemukan pada prediksi skala pendek karena tingginya variabilitas cuaca. Secara keseluruhan, studi ini menegaskan bahwa pendekatan hybrid berbasis optimasi cerdas merupakan solusi efektif untuk sistem peringatan dini kekeringan berbasis machine learning.

4. Penelitian “An improved SPEI drought forecasting approach using the long short-term memory neural network” oleh Dikshit et al. (2021) [15].

Penelitian oleh Dikshit et al. (2021) mengembangkan model peramalan kekeringan berbasis *Long Short-Term Memory* (LSTM) untuk memprediksi indeks SPEI pada skala waktu SPEI-1 dan SPEI-3 menggunakan data klimatologi global CRU periode 1901–2018. Model memanfaatkan variabel meteorologis seperti curah hujan, temperatur, evapotranspirasi potensial, tekanan uap, dan tutupan awan, dengan pendekatan time-series multivariat yang mempertimbangkan hingga 20 langkah waktu sebelumnya. Arsitektur yang digunakan relatif sederhana, terdiri dari satu layer LSTM dan satu dense layer, namun mampu menghasilkan performa prediksi yang sangat tinggi dengan nilai koefisien determinasi ( $R^2$ ) mencapai 0.996–0.998 serta error yang rendah. Analisis spasio-temporal menunjukkan bahwa model mampu merepresentasikan distribusi kekeringan secara konsisten dengan data observasi, meskipun terdapat kecenderungan overestimasi pada beberapa kondisi ekstrem. Evaluasi klasifikasi kekeringan menggunakan ROC-AUC menghasilkan nilai sekitar 0.82–0.83, yang menunjukkan kemampuan baik dalam membedakan kategori kekeringan. Penelitian ini menegaskan bahwa pendekatan deep learning, khususnya LSTM, lebih efektif dibanding metode machine learning konvensional dalam menangani karakteristik data kekeringan yang nonlinier dan non-stasioner, meskipun masih memiliki keterbatasan pada akurasi batas kategori kekeringan.

5. Penelitian “Application of Informer Model Based on SPEI for Drought Forecasting” oleh Shang et al. (2023) [17].

Penelitian oleh Shang et al. (2023) mengusulkan penggunaan model Informer, yaitu arsitektur berbasis Transformer yang dioptimalkan untuk time series panjang, dalam peramalan kekeringan berbasis indeks SPEI pada berbagai skala waktu di Basin Sungai Kuning, China. Studi ini membandingkan performa Informer dengan model konvensional seperti ARIMA dan LSTM menggunakan data meteorologi periode 1960–2019 dari empat stasiun pengamatan. Hasil penelitian menunjukkan bahwa akurasi prediksi meningkat seiring bertambahnya skala waktu (dari SPEI-1 hingga SPEI-24), namun Informer secara konsisten mengungguli kedua model pembanding pada seluruh skala.

Secara khusus, Informer mampu menghasilkan nilai prediksi yang lebih mendekati data aktual serta mengikuti pola tren SPEI dengan lebih baik, terutama pada skala menengah hingga panjang. Hal ini disebabkan oleh kemampuan Informer dalam menangkap dependensi jangka panjang melalui mekanisme self-attention serta efisiensi komputasi melalui ProbSparse attention. Evaluasi menggunakan metrik seperti MAE, RMSE, dan NSE menunjukkan bahwa Informer memiliki error lebih rendah dan nilai NSE lebih tinggi, dengan performa terbaik pada skala SPEI-24 (NSE hingga  $\sim 0.98$ ). Namun, penelitian ini juga mengidentifikasi keterbatasan pada skala pendek (SPEI-1), di mana seluruh model mengalami penurunan akurasi akibat tingginya fluktuasi data. Secara keseluruhan, studi ini menegaskan bahwa model berbasis Transformer seperti Informer memiliki potensi signifikan dalam meningkatkan akurasi peramalan kekeringan multi-skala, khususnya untuk horizon waktu yang lebih panjang.

6. Penelitian “Next-Generation Drought Forecasting: Hybrid AI Models for Climate Resilience” oleh Liu et al. (2025) [19].

Penelitian oleh Liu et al. (2025) mengembangkan kerangka peramalan kekeringan berbasis hybrid artificial intelligence yang mengintegrasikan metode machine learning dan deep learning dengan data historis serta proyeksi iklim masa depan. Studi ini memanfaatkan data TerraClimate periode 1985–2014 dan proyeksi CMIP6 periode 2030–2050 pada skenario SSP2-4.5 dan SSP5-8.5 untuk memodelkan indeks kekeringan Palmer Drought Severity Index (PDSI) di wilayah Inner Mongolia, Basins Sungai Kuning. Hasil pada penelitian ini menunjukkan bahwa kombinasi Random Forest dan Long Short-Term Memory (LSTM) memberikan performa terbaik dibandingkan model lain seperti XGBoost, SVR, dan Gradient Boosting, di mana Random Forest digunakan untuk mengidentifikasi variabel paling berpengaruh seperti curah hujan, radiasi matahari, dan suhu maksimum, sementara LSTM digunakan untuk menangkap pola temporal jangka panjang. Model LSTM menghasilkan akurasi tinggi dengan nilai  $R^2$  sekitar 0,766 dan RMSE sekitar 0,885, serta mampu merepresentasikan dinamika kekeringan secara lebih stabil. Selain itu, hasil proyeksi menunjukkan peningkatan intensitas dan frekuensi kekeringan setelah

tahun 2040, terutama pada skenario SSP5-8.5 dengan nilai PDSI yang cenderung masuk kategori kekeringan ekstrem. Penelitian ini menegaskan bahwa pendekatan hybrid AI efektif dalam meningkatkan akurasi prediksi sekaligus memberikan dasar yang kuat untuk sistem peringatan dini dan perencanaan adaptasi perubahan iklim, meskipun masih memiliki keterbatasan pada aspek ketidakpastian proyeksi dan belum memasukkan faktor non-klimatik.

7. Penelitian “S-Transformer: A New Deep Learning Model Enhanced by Sequential Transformer Encoders for Drought Forecasting” oleh Danandeh Mehr et al. (2025) [20].

Penelitian ini mengusulkan model deep learning baru bernama S-Transformer, yang merupakan pengembangan dari arsitektur Transformer encoder dengan integrasi mekanisme sekuensial berbasis window untuk meningkatkan akurasi peramalan kekeringan. Model ini dirancang untuk memprediksi indeks kekeringan meteorologis SPI dengan memanfaatkan data historis dalam bentuk urutan waktu yang dibagi menjadi window dinamis, sehingga model dapat menangkap pola temporal secara lebih adaptif. Berbeda dengan Transformer klasik, pendekatan ini memungkinkan pembaruan bobot secara bertahap berdasarkan potongan data berurutan, meningkatkan kemampuan generalisasi model. Studi dilakukan pada dua wilayah di Turki (Burdur dan Isparta) menggunakan data SPI-6 periode 1971–2021, dengan perbandingan terhadap model MLP, LSTM, dan Transformer standar. Hasil penelitian menunjukkan bahwa S-Transformer secara konsisten menghasilkan performa terbaik dengan nilai RMSE sangat rendah (sekitar 0,096–0,098 pada data uji) serta nilai NSE yang tinggi, menunjukkan akurasi dan stabilitas prediksi yang unggul dibanding model pembandingan. Selain itu, model ini terbukti lebih mampu menangkap pola musiman dan kejadian ekstrem (kekeringan parah), yang sering diremehkan oleh model lain. Namun demikian, kompleksitas komputasi menjadi salah satu keterbatasan utama, terutama pada data skala besar. Secara keseluruhan, penelitian ini menegaskan bahwa modifikasi arsitektur Transformer berbasis sekuensial dapat meningkatkan kinerja peramalan time series kekeringan secara signifikan, sekaligus menawarkan alternatif yang lebih sederhana dibanding model hybrid kompleks.

8. Penelitian “SPEI Drought Forecasting in Central Mexico” oleh Carrillo-Carrillo et al. (2025) [13].

Penelitian ini membandingkan tiga model peramalan kekeringan berbasis Standardized Precipitation Evapotranspiration Index (SPEI), yaitu Kalman Filter dengan variabel eksogen (DKF-ARX-Pt), Gated Recurrent Unit (GRU), dan Neural Autoregressive with Exogenous Input (NARX), menggunakan data 23 stasiun meteorologi periode 1981–2023 di wilayah Meksiko. Pada penelitian ini disebutkan bahwa SPEI dipilih karena mampu mengintegrasikan curah hujan dan evapotranspirasi sehingga lebih representatif terhadap kondisi kekeringan. Model dikembangkan dengan pendekatan time series menggunakan input 36 bulan sebelumnya dan divalidasi dengan pembagian data 70% pelatihan dan 30% pengujian serta metrik evaluasi seperti MAE, RMSE,  $R^2$ , NSE, dan KGE. Hasil pada penelitian ini menunjukkan bahwa model NARX memiliki akurasi terbaik secara rata-rata dengan error paling rendah dan nilai kesesuaian tertinggi, namun memiliki kelemahan pada kompleksitas komputasi dan kestabilan. Sebaliknya, model Kalman Filter menunjukkan performa paling konsisten di berbagai skala waktu dengan nilai  $R^2$  dan NSE di atas 0,97 serta KGE positif, serta memiliki efisiensi komputasi yang jauh lebih baik. Sementara itu, GRU memberikan performa cukup baik pada skala menengah tetapi kurang stabil pada skala pendek. Secara keseluruhan, penelitian ini menegaskan bahwa Kalman Filter merupakan pendekatan paling andal untuk implementasi operasional, sedangkan model deep learning lebih unggul dalam akurasi namun membutuhkan optimasi lebih lanjut.

9. Penelitian “Drought prediction across Vietnam using a hybrid approach” oleh Quynh Hoa et al. (2025) [16].

Penelitian ini mengembangkan pendekatan model hybrid berbasis Artificial Neural Network (ANN) untuk peramalan kekeringan menggunakan indeks SPEI-6 di seluruh wilayah Vietnam, dengan tujuan meningkatkan akurasi prediksi melalui integrasi model dinamis dan statistik. Pada penelitian ini disebutkan bahwa pendekatan tradisional berbasis presipitasi saja memiliki keterbatasan dalam merepresentasikan kompleksitas kekeringan, sehingga digunakan kombinasi data observasi, model iklim regional (RCMs seperti

CWRF dan RegCM), serta teknik bias correction sebelum digunakan dalam model ANN. Arsitektur yang dikembangkan mencakup dua skema utama (ANN1 dan ANN2) serta pendekatan ensemble untuk menggabungkan hasil prediksi dan mengurangi ketidakpastian model. Hasil pada penelitian ini menunjukkan bahwa model hybrid (CTL) secara konsisten mengungguli metode ensemble sederhana (ENS), dengan korelasi tinggi (sekitar 0,73–0,95) pada berbagai wilayah dan lead time, serta performa terbaik pada horizon pendek (1–3 bulan). Namun, performa model mengalami penurunan pada horizon yang lebih panjang, khususnya dalam menangkap intensitas kejadian ekstrem, yang cenderung tereduksi akibat efek smoothing dari proses bias correction dan ensemble. Selain itu, ditemukan adanya variasi spasial yang signifikan, di mana akurasi model berbeda antar sub-wilayah, menunjukkan pentingnya mempertimbangkan heterogenitas iklim regional. Secara keseluruhan, penelitian ini menegaskan bahwa pendekatan hybrid berbasis ANN mampu meningkatkan reliabilitas peramalan kekeringan multi-step, namun tetap menghadapi tantangan dalam mempertahankan akurasi pada horizon panjang dan dalam menangkap ekstrem iklim secara presisi.

10. Penelitian “Development of a new wavelet-based hybrid model to forecast multi-scalar SPEI drought index (case study Zanzan city, Iran)” oleh Karbasi et al. (2021) [29].

Penelitian oleh Karbasi et al. (2021) mengusulkan pendekatan hybrid dengan mengombinasikan transformasi wavelet dan model machine learning (GPR, Cascade-NN, dan MLP) untuk meningkatkan akurasi peramalan indeks kekeringan SPEI pada berbagai skala waktu. Pada penelitian ini disebutkan bahwa data historis selama 57 tahun digunakan untuk memprediksi SPEI-3, SPEI-12, dan SPEI-24 dengan horizon 1 hingga 6 bulan ke depan. Metode yang digunakan melibatkan dekomposisi deret waktu menjadi komponen frekuensi rendah dan tinggi sebelum dimasukkan ke dalam model, sehingga pola non-stasioner dapat ditangkap lebih baik. Hasil pada penelitian ini menunjukkan bahwa model hybrid berbasis wavelet secara konsisten mengungguli model tunggal, dengan kombinasi dmey wavelet dan GPR memberikan performa terbaik ( $R^2$  hingga 0,998 dan RMSE sangat rendah). Namun, akurasi menurun

pada horizon prediksi yang lebih panjang, menunjukkan keterbatasan dalam menangani ketidakpastian jangka panjang

| No | Judul                                                                                                                                            | Metode                            | Hasil                                                                                                           | Keterangan                                               |
|----|--------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------|-----------------------------------------------------------------------------------------------------------------|----------------------------------------------------------|
| 1  | Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting [24]                                                        | Temporal Fusion Transformer (TFT) | Unggul dalam multi-horizon forecasting dengan interpretabilitas bawaan (Variable Selection Network + Attention) | Fondasi arsitektur utama penelitian ini                  |
| 2  | Application of Informer Model Based on SPEI for Drought Forecasting [17]                                                                         | Informer (berbasis Transformer)   | Mengungguli ARIMA dan LSTM pada peramalan SPEI multi-skala (1–24 bulan)                                         | Penerapan Transformer pertama kali pada SPEI             |
| 3  | S-Transformer: A New Deep Learning Model Enhanced by Sequential Transformer Encoders for Drought Forecasting [20]                                | S-Transformer                     | Akurasi tertinggi dan stabil pada prediksi indeks kekeringan (RMSE rendah, NSE tinggi)                          | Modifikasi Transformer terbaru untuk drought forecasting |
| 4  | Sistem Peramalan Multi-Horizon Kekeringan Lahan Pertanian di Sentra Padi Jawa Timur Berbasis Indeks SPEI Menggunakan Temporal Fusion Transformer | Temporal Fusion Transformer (TFT) | -                                                                                                               | Penelitian Saat Ini                                      |

Berdasarkan Tabel 2.2, ketiga penelitian terdahulu yang paling relevan menunjukkan perkembangan signifikan dalam penerapan arsitektur berbasis Transformer untuk peramalan indeks kekeringan. Lim et al. (2021)[24] memperkenalkan Temporal Fusion Transformer (TFT) sebagai model multi-horizon yang interpretabel, sementara Shang et al. (2023)[17] dan Danandeh Mehr

et al. (2025)[20] telah mengadaptasi varian Transformer (Informer dan S-Transformer) untuk memprediksi indeks kekeringan (SPEI dan SPI). Namun, ketiga penelitian tersebut masih memiliki keterbatasan, yaitu belum mengintegrasikan secara simultan prediksi probabilistik berbasis quantile, kalibrasi spasial per lokasi, serta analisis interpretabilitas mendalam dalam konteks peramalan SPEI-3 untuk kekeringan pertanian regional. Penelitian ini melengkapi celah tersebut dengan mengimplementasikan Temporal Fusion Transformer secara penuh untuk peramalan multi-horizon SPEI-3 secara probabilistik pada lima sentra padi di Jawa Timur, dilengkapi dengan kalibrasi per lokasi dan pemanfaatan mekanisme interpretabilitas bawaan TFT.

## **2.2 Landasan Teori**

Landasan teori ini menjadi fondasi konseptual dan metodologis yang merupakan dasar bagi pengembangan penelitian ini. Bagian ini membahas secara sistematis konsep-konsep utama yang mendasari peramalan multi-horizon indeks kekeringan SPEI-3 menggunakan Temporal Fusion Transformer (TFT) pada sentra padi di Jawa Timur. Pembahasan dimulai dari pemahaman mendalam mengenai kekeringan pertanian sebagai fenomena hidrometeorologis yang berdampak langsung terhadap produktivitas tanaman padi, dilanjutkan dengan penjelasan mengenai indeks Standardized Precipitation Evapotranspiration Index (SPEI) beserta prinsip perhitungannya. Selanjutnya, dibahas karakteristik dan tantangan peramalan time series iklim, konsep multi-horizon forecasting, peramalan probabilistik beserta kalibrasi prediksinya, hingga arsitektur Temporal Fusion Transformer. Bagian ini juga menjelaskan mekanisme attention dan interpretabilitas model yang menjadi keunggulan utama TFT. Dengan demikian, landasan teori ini tidak hanya memberikan kerangka ilmiah yang kokoh, tetapi juga menjelaskan alasan pemilihan variabel input, skala SPEI-3, horizon prediksi 30 hari, serta pendekatan probabilistik dan interpretatif yang digunakan dalam penelitian ini.

### **2.2.1 Kekeringan Pertanian**

Kekeringan pertanian (agricultural drought) merupakan salah satu ancaman utama terhadap produktivitas tanaman padi di Indonesia, khususnya di Provinsi Jawa Timur sebagai salah satu lumbung padi nasional. Kekeringan pertanian terjadi



ketika ketersediaan air di zona perakaran tanaman tidak mencukupi kebutuhan air untuk pertumbuhan dan produksi tanaman secara optimal. Kondisi ini ditandai oleh defisit kelembaban tanah akibat berkurangnya presipitasi dan/atau peningkatan evapotranspirasi, yang pada akhirnya menyebabkan penurunan hasil panen bahkan gagal panen (puso) [4], [32].

Di Jawa Timur, kekeringan pertanian sering melanda sentra produksi padi seperti Bojonegoro, Lamongan, Ngawi, Nganjuk, dan Tuban. Karim et al. (2023)[32] memetakan wilayah rentan kekeringan pada lahan padi di Jawa Timur dan menemukan bahwa Bojonegoro serta Lamongan termasuk kategori sangat rentan, dengan luas area terdampak kekeringan mencapai ribuan hektar pada tahun-tahun kemarau panjang. Penelitian lain juga menunjukkan bahwa kekeringan menyebabkan penurunan luas panen padi dan peningkatan risiko gagal panen di wilayah ini, terutama akibat fenomena El Niño yang memperpanjang musim kemarau [4], [32].

Kekeringan pertanian memiliki karakteristik yang berbeda dengan kekeringan meteorologis karena sangat dipengaruhi oleh interaksi antara defisit kelembaban tanah, ketidakseimbangan evapotranspirasi, dan sensitivitas tanaman terhadap fase pertumbuhan. Pada tanaman padi, fase vegetatif relatif lebih toleran, sedangkan fase pembungaan dan pengisian bulir sangat sensitif terhadap cekaman kekeringan, sehingga dapat menyebabkan peningkatan gabah hampa dan penurunan bobot bulir secara signifikan [4], [33].

Dalam konteks perubahan iklim, frekuensi, durasi, dan intensitas kekeringan pertanian di Jawa Timur cenderung meningkat, sehingga memerlukan pendekatan peramalan yang akurat dan dini untuk mendukung pengambilan keputusan di sektor pertanian. Oleh karena itu, Pemahaman yang mendalam mengenai kekeringan pertanian menjadi landasan penting dalam penelitian ini, karena menjadi dasar bagi pemilihan indeks SPEI-3 sebagai indikator utama dan pengembangan sistem peramalan multi-horizon menggunakan Temporal Fusion Transformer untuk mendukung peringatan dini di sentra padi Jawa Timur.

## 2.2.2 Indeks Kekeringan dan Standardized Precipitation Evapotranspiration Index (SPEI)

Indeks kekeringan dikembangkan untuk mengubah informasi hidrometeorologis yang kompleks menjadi ukuran terstandarisasi yang dapat dibandingkan lintas wilayah dan waktu. Dalam konteks pertanian, pemilihan indeks yang tepat sangat penting untuk memantau dan meramalkan kondisi kekeringan yang memengaruhi ketersediaan air bagi tanaman padi. Penelitian ini menggunakan Standardized Precipitation Evapotranspiration Index (SPEI) karena kemampuannya mengintegrasikan presipitasi dan evapotranspirasi potensial, sehingga lebih sensitif terhadap perubahan suhu dan dinamika iklim dibandingkan indeks lain seperti Standardized Precipitation Index (SPI) [8], [9], [12].

### 2.2.2.1 Konsep dan Keunggulan SPEI

SPEI merupakan indeks kekeringan berbasis neraca air yang menghitung selisih antara presipitasi ( $P$ ) dan evapotranspirasi potensial ( $ET_0$ ), kemudian distandardisasi secara probabilistik. Keunggulan utama SPEI dibandingkan SPI adalah kemampuannya memasukkan pengaruh suhu melalui komponen  $ET_0$ , sehingga lebih representatif dalam mendeteksi kekeringan pertanian di era perubahan iklim [8], [10], [15]. Berbagai studi menunjukkan bahwa SPEI memiliki korelasi yang lebih kuat dengan hasil panen dibandingkan indeks berbasis presipitasi semata [10].

Tabel 2.1 Klasifikasi dan Kategori Indeks Kekeringan [13], [15]

| Nilai Indeks    | Kategori              |
|-----------------|-----------------------|
| $> 2.00$        | Sangat lembap ekstrem |
| $1.50 - 1.99$   | Sangat lembap         |
| $1.00 - 1.49$   | Lembap sedang         |
| $-0.99 - 0.99$  | Mendekati normal      |
| $-1.00 - -1.49$ | Kekeringan sedang     |
| $-1.50 - -1.99$ | Kekeringan berat      |
| $< -2.00$       | Kekeringan ekstrem    |

Keunggulan lain dari indeks kekeringan berbasis iklim adalah fleksibilitas dalam penggunaan skala waktu akumulasi. Dengan menggunakan skala waktu berbeda misalnya 1 hingga 24 bulan, indeks yang sama dapat merepresentasikan

berbagai jenis kekeringan, mulai dari kekeringan meteorologis hingga hidrologis. Dalam konteks pertanian, indeks yang memasukkan komponen evapotranspirasi memiliki kelebihan karena tidak hanya menangkap input air dari presipitasi, tetapi juga permintaan atmosferik yang memengaruhi laju pengeringan tanah dan stres air tanaman [10], [13].

#### **2.2.2.2 Prinsip Dasar Perhitungan SPEI**

Secara teoretis, SPEI dibangun melalui dua langkah utama. Langkah pertama adalah menghitung neraca air bulanan sebagai selisih antara presipitasi dan evapotranspirasi potensial yang dirumuskan  $D_i = P_i - ET0_i$

di mana  $P_i$  merupakan presipitasi dan  $ET0_i$  adalah evapotranspirasi potensial pada periode ke- $i$ . Nilai neraca air ini kemudian diakumulasikan pada jendela waktu tertentu (misalnya 1, 3, 6, atau 12 bulan) untuk menghasilkan seri neraca air akumulatif yang merepresentasikan kondisi kekeringan pada skala waktu yang berbeda [15].

Langkah kedua adalah menyesuaikan distribusi probabilitas terhadap seri neraca air tersebut dan mentransformasikannya menjadi nilai terstandarisasi (*z-score*). Proses ini menghasilkan indeks dengan rata-rata nol dan simpangan baku satu, sehingga nilai SPEI dapat ditafsirkan sebagai derajat kejaran suatu kejadian. Misalnya, nilai SPEI di bawah  $-1$  menunjukkan kondisi kering, sedangkan nilai di bawah  $-1,5$  menunjukkan kekeringan berat [13].

Pendekatan probabilistik ini memungkinkan interpretasi indeks dalam kerangka risiko dan frekuensi kejadian, sekaligus memungkinkan perbandingan kondisi kekeringan antar wilayah dengan karakteristik iklim yang berbeda.

#### **2.2.2.3 Peran Evapotranspirasi dalam Analisis Kekeringan**

Salah satu keunggulan terbesar SPEI adalah penggunaan evapotranspirasi potensial ( $ET0$ ) sebagai komponen utama.  $ET0$  dihitung menggunakan metode FAO-Penman-Monteith yang mempertimbangkan faktor suhu udara, radiasi matahari, kecepatan angin, dan kelembaban relatif. Komponen ini sangat penting karena mencerminkan permintaan air dari atmosfer terhadap tanah dan tanaman [15].

Dalam kondisi perubahan iklim yang ditandai dengan peningkatan suhu global, nilai  $ET0$  cenderung meningkat meskipun presipitasi relatif stabil. Hal ini

menyebabkan defisit neraca air semakin besar, sehingga memperburuk kondisi kekeringan pertanian. Oleh karena itu, SPEI yang memasukkan  $ET_0$  jauh lebih sensitif dan akurat dibandingkan SPI yang hanya berbasis presipitasi [12], [15]. Penggunaan  $ET_0$  juga membuat SPEI lebih sesuai untuk memantau kekeringan pada tanaman padi yang sangat bergantung pada keseimbangan antara pasokan air hujan dan kehilangan air melalui evapotranspirasi.

#### **2.2.2.4 Alasan Teoretis Pemilihan SPEI-3**

Pemilihan SPEI-3 sebagai target prediksi dalam penelitian ini didasarkan pada beberapa pertimbangan teoretis. Pertama, skala waktu tiga bulan sebanding dengan durasi fase penting dalam siklus pertumbuhan tanaman padi, sehingga mampu merepresentasikan akumulasi defisit air yang memengaruhi pertumbuhan tanaman [15].

Kedua, SPEI-3 merupakan kompromi antara sensitivitas terhadap perubahan cuaca dan stabilitas statistik. Skala ini cukup panjang untuk mengurangi fluktuasi jangka sangat pendek, tetapi tetap cukup responsif terhadap perubahan kondisi musiman [12], [13].

Ketiga, informasi mengenai kondisi kekeringan pada horizon beberapa bulan ke depan sangat penting bagi manajemen pertanian, seperti penyesuaian kalender tanam, pemilihan varietas tanaman, serta strategi irigasi. Oleh karena itu, penggunaan SPEI-3 dalam sistem peramalan kekeringan pertanian dianggap relevan untuk mendukung sistem peringatan dini berbasis risiko.

#### **2.2.2.5 Keterbatasan SPEI**

Meskipun memiliki banyak keunggulan, SPEI juga memiliki beberapa keterbatasan. Pertama, karena berbasis neraca air dan distribusi probabilitas historis, SPEI bersifat sensitif terhadap kondisi iklim lokal. Hal ini berarti bahwa kinerja indeks dapat berbeda antar wilayah dan musim, sehingga perlu dilakukan evaluasi regional sebelum digunakan secara operasional [8].

Kedua, SPEI sangat bergantung pada kualitas data klimatologis, khususnya presipitasi dan estimasi evapotranspirasi potensial. Kesalahan pengukuran atau bias data dapat memengaruhi hasil indeks dan interpretasi kondisi kekeringan [13].

Ketiga, proses standarisasi SPEI mengasumsikan kestasioneran statistik pada periode referensi historis, sementara perubahan iklim jangka panjang dapat

mengubah distribusi presipitasi dan evapotranspirasi. Oleh karena itu, interpretasi tren jangka panjang perlu dilakukan dengan hati-hati.

Meskipun demikian, berbagai penelitian menunjukkan bahwa SPEI tetap menjadi salah satu indeks yang paling efektif untuk memantau dan memprediksi kekeringan pertanian karena kemampuannya mengintegrasikan presipitasi dan evapotranspirasi dalam kerangka neraca air yang sederhana namun representatif [8], [10], [15].

### **2.2.3 Peramalan Time Series Iklim**

Peramalan time series iklim merupakan proses memprediksi nilai variabel hidrometeorologis di masa depan berdasarkan pola historis. Dalam konteks kekeringan pertanian, peramalan ini sangat penting untuk mendukung sistem peringatan dini, khususnya pada indeks SPEI-3 yang mencerminkan kondisi kelembaban tanah selama musim tanam padi. Tantangan utama peramalan time series iklim adalah sifat data yang non-linear, non-stasioner, dan dipengaruhi oleh variabilitas musiman serta perubahan iklim jangka panjang [12], [15].

Keberhasilan peramalan SPEI-3 bergantung pada kemampuan model dalam menangkap dependensi temporal dan interaksi multivariat antar variabel iklim. Pendekatan modern seperti Temporal Fusion Transformer (TFT) dirancang khusus untuk mengatasi kompleksitas ini, sehingga menjadi pilihan utama dalam penelitian ini untuk peramalan multi-horizon di sentra padi Jawa Timur [24], [30].

#### **2.2.3.1 Karakteristik Time Series Iklim dan Tantangan Peramalan**

Time series indeks kekeringan dan variabel iklim seperti presipitasi, suhu, dan  $ET_0$  memiliki karakteristik non-linear dan non-stasioner yang menyulitkan pemodelan. Perubahan iklim menyebabkan distribusi data berubah dari waktu ke waktu, sehingga asumsi stasioneritas pada model tradisional sering tidak terpenuhi [12], [28].

Data iklim juga bersifat noisy dan memiliki komponen musiman yang kuat, dipengaruhi oleh monsun, ENSO, serta pola curah hujan regional di Jawa Timur. Hal ini menyebabkan fluktuasi tinggi pada skala waktu pendek, sementara pola jangka panjang lebih stabil [15], [29]. Tantangan ini semakin kompleks pada peramalan multi-horizon karena ketidakpastian meningkat seiring bertambahnya lead time.

Dalam konteks pertanian padi, karakteristik ini berdampak langsung pada akurasi prediksi SPEI-3. Model yang tidak mampu menangkap dependensi jangka panjang akan gagal mendeteksi risiko kekeringan musiman di wilayah seperti Bojonegoro dan Lamongan [33], [12].

#### **2.2.3.2 Keterbatasan Metode Statistik Tradisional**

Metode statistik klasik seperti ARIMA dan regresi linier mengasumsikan linearitas dan stasioneritas data, sehingga kurang efektif untuk time series iklim yang kompleks. Model-model ini kesulitan menangkap interaksi non-linear antara presipitasi, suhu, dan ETo yang memengaruhi SPEI-3 [12], [14].

Pada horizon prediksi yang lebih panjang, performa metode tradisional menurun drastis karena akumulasi kesalahan dan ketidakmampuan memodelkan pola musiman serta perubahan rezim iklim. Studi di berbagai wilayah menunjukkan bahwa ARIMA kurang akurat untuk peramalan kekeringan pertanian di daerah tropis [12], [17].

Keterbatasan ini mendorong perkembangan pendekatan hybrid dan deep learning. Meskipun hybrid seperti ARIMA-LSTM meningkatkan akurasi, model tersebut masih memiliki keterbatasan interpretabilitas dan kesulitan mengintegrasikan kovariat multivariat secara optimal [12], [19].

#### **2.2.3.3 Perkembangan Pendekatan Machine Learning dan Deep Learning**

Pendekatan machine learning seperti XGBoost dan deep learning seperti LSTM menunjukkan peningkatan signifikan dalam peramalan time series iklim. Model-model ini mampu menangkap pola non-linear dan dependensi jangka panjang tanpa asumsi distribusi tertentu [14], [15], [20].

Dalam peramalan SPEI, LSTM dan varian Transformer seperti Informer telah berhasil mengungguli metode tradisional, terutama pada skala waktu menengah hingga panjang. Kemampuan ini sangat relevan untuk mendukung peringatan dini kekeringan pada lahan padi di Jawa Timur [17], [20].

Perkembangan terkini mengarah pada arsitektur yang tidak hanya akurat tetapi juga interpretable, seperti Temporal Fusion Transformer (TFT). Model ini mengintegrasikan variable selection, attention mechanism, dan quantile output, sehingga cocok untuk peramalan multi-horizon SPEI-3 dengan dukungan interpretabilitas yang tinggi [24], [30].

#### 2.2.4 Multi-Horizon Time Series Forecasting

Multi-horizon forecasting adalah pendekatan peramalan yang memprediksi nilai target pada beberapa horizon waktu secara simultan dalam satu proses komputasi, bukan secara berurutan. Konsep ini sangat relevan untuk peramalan SPEI-3 karena memungkinkan prediksi lintasan kekeringan hingga 30 hari ke depan, sehingga petani di sentra padi Jawa Timur dapat melakukan persiapan yang lebih matang terhadap risiko defisit air [24], [30].


Berbeda dengan peramalan satu-langkah tradisional yang hanya menghasilkan satu nilai prediksi, multi-horizon forecasting menghasilkan vektor prediksi lengkap  $\{y_{t+1}, \dots, y_{t+\tau}\}$ . Penerapan konsep ini dalam model Temporal Fusion Transformer memungkinkan integrasi kovariat heterogen dan analisis degradasi performa antar-horizon, sehingga meningkatkan keandalan sistem peringatan dini kekeringan pertanian [24], [12].

##### 2.2.4.1 Definisi dan Skema Multi-Horizon Forecasting

Multi-horizon forecasting didefinisikan sebagai pemodelan langsung terhadap beberapa langkah waktu masa depan secara bersamaan. Skema utamanya meliputi direct multi-output (satu model menghasilkan seluruh horizon), recursive (menggunakan prediksi sebelumnya sebagai input), dan hybrid. Direct multi-output menjadi pilihan utama karena menghindari propagasi kesalahan dan menjaga konsistensi lintas-horizon [24], [30].

Dalam konsep ini, model belajar tidak hanya pola historis, tetapi juga dependensi antar-horizon prediksi. Penerapan pada SPEI-3 memungkinkan model memprediksi evolusi kekeringan dari horizon pendek (1–7 hari) hingga menengah (8–30 hari) dalam satu kali inferensi, yang sangat bermanfaat untuk perencanaan irigasi di lahan padi Jawa Timur [12], [33].

Keunggulan konsep ini adalah kemampuan mengintegrasikan berbagai jenis input (static, known future, observed) secara sistematis. Hal ini membuat multi-horizon forecasting lebih adaptif terhadap data iklim non-stasioner dibandingkan metode konvensional [24], [30].



Gambar 2.1 Ilustrasi Peramalan Multi-Horizon [24], [30]

#### 2.2.4.2 Keunggulan dan Tantangan Pendekatan Multi-Horizon

Keunggulan utama multi-horizon forecasting adalah konsistensi lintas-horizon dan stabilitas degradasi performa. Model dapat meminimalkan kesalahan secara simultan, sehingga profil prediksi lebih halus dan realistis. Dalam penerapan pada SPEI-3, pendekatan ini memberikan gambaran lengkap tentang intensifikasi kekeringan selama beberapa minggu, sehingga mendukung keputusan operasional petani di Bojonegoro dan Lamongan [24], [31].

Tantangan utamanya adalah peningkatan ketidakpastian seiring bertambahnya horizon serta kebutuhan data historis yang cukup panjang. Di wilayah Jawa Timur dengan variabilitas monsun tinggi, model harus mampu menangani noise dan perubahan rezim iklim agar prediksi tetap akurat [12], [28].

Meskipun menantang, penerapan multi-horizon forecasting jauh lebih sesuai untuk sistem peringatan dini kekeringan pertanian dibandingkan peramalan satu-langkah, karena memberikan lintasan kondisi kekeringan yang actionable bagi pemangku kepentingan [30], [33].



#### **2.2.4.3 Relevansi Multi-Horizon untuk Peringatan Dini Kekeringan**

##### **Pertanian**

Relevansi multi-horizon forecasting sangat tinggi dalam peringatan dini kekeringan pertanian padi. Konsep ini memungkinkan prediksi lintasan SPEI-3 hingga 30 hari, sehingga petani dapat menyesuaikan jadwal tanam, strategi irigasi, atau pemilihan varietas tahan kekeringan di sentra Jawa Timur [33], [12].

Penerapan konsep ini dalam Temporal Fusion Transformer juga memfasilitasi analisis degradasi performa antar-horizon, sehingga batas keandalan prediksi dapat ditentukan secara jelas. Hal ini krusial untuk menghindari keputusan yang salah akibat prediksi yang tidak akurat pada horizon panjang [24], [30].

Dengan demikian, multi-horizon forecasting tidak hanya meningkatkan akurasi, tetapi juga nilai praktis sistem peramalan SPEI-3. Pendekatan ini mendukung pengambilan keputusan berbasis risiko di lahan padi Jawa Timur yang rentan terhadap kekeringan musiman [33], [31].

#### **2.2.5 Peramalan Probabilistik dan Ketidakpastian Prediksi**

Peramalan probabilistik tidak hanya menghasilkan satu nilai prediksi (point forecast), tetapi juga distribusi kemungkinan beserta tingkat ketidakpastiannya. Dalam konteks kekeringan pertanian, pendekatan ini sangat penting karena petani dan pemerintah di Jawa Timur memerlukan informasi risiko, bukan hanya nilai SPEI-3 rata-rata, untuk mengambil keputusan mitigasi yang tepat [25], [26].

Berbeda dengan peramalan deterministik yang hanya memberikan satu angka, peramalan probabilistik menghasilkan quantile (P10, P50, P90) yang membentuk interval prediksi. Penerapan konsep ini dalam Temporal Fusion Transformer memungkinkan model menyajikan skenario terbaik hingga terburuk, sehingga meningkatkan kepercayaan pengguna dalam sistem peringatan dini kekeringan lahan padi [24], [25].

##### **2.2.5.1 Perbandingan Deterministic dan Probabilistic Forecast**

Peramalan deterministik menghasilkan satu nilai tunggal sebagai estimasi masa depan, seperti nilai SPEI-3 sebesar -1.2. Pendekatan ini umum digunakan pada model LSTM atau XGBoost, tetapi tidak memberikan informasi mengenai seberapa besar kemungkinan terjadinya kekeringan parah [12], [19].

Sebaliknya, peramalan probabilistik memodelkan distribusi kemungkinan nilai. Dalam penerapan pada SPEI-3, model menghasilkan P10 (skenario basah), P50 (prediksi median), dan P90 (skenario kering), sehingga petani dapat menilai risiko gagal panen di sentra padi Jawa Timur [25], [26].

Perbedaan mendasar ini membuat probabilistic forecast lebih sesuai untuk pengambilan keputusan berbasis risiko. Studi menunjukkan bahwa informasi probabilistik meningkatkan efektivitas sistem peringatan dini dibandingkan prediksi deterministik semata [25], [3].

#### **2.2.5.2 Quantile Forecasting dan Prediction Interval**

Quantile forecasting adalah metode utama dalam peramalan probabilistik yang memprediksi kuantil tertentu dari distribusi target. Temporal Fusion Transformer menggunakan quantile loss untuk menghasilkan P10, P50, dan P90 secara simultan pada setiap horizon multi-horizon [24].

Prediction interval yang dihasilkan (misalnya P10–P90) merepresentasikan rentang nilai di mana sekitar 80% kemungkinan SPEI-3 akan berada. Penerapan ini sangat relevan untuk kekeringan pertanian karena memungkinkan petani mempersiapkan skenario terburuk (P90) di wilayah rawan seperti Lamongan dan Bojonegoro [26], [30].

Keunggulan quantile forecasting adalah kemampuannya menghasilkan interval yang tajam (sharp) sekaligus reliabel. Dalam model TFT, interval ini dapat dikalibrasi per lokasi untuk menyesuaikan heterogenitas iklim di Jawa Timur [24], [25].

#### **2.2.5.3 Pentingnya Kalibrasi (Global vs Per Lokasi)**

Kalibrasi adalah proses menyesuaikan distribusi prediksi agar sesuai dengan frekuensi kejadian aktual di dunia nyata. Tanpa kalibrasi, interval prediksi dapat terlalu sempit (under-dispersion) atau terlalu lebar (over-dispersion), sehingga mengurangi kepercayaan petani terhadap ramalan SPEI-3 [26].

Kalibrasi global menerapkan satu koreksi untuk seluruh wilayah, sementara kalibrasi per lokasi menyesuaikan parameter untuk setiap kabupaten. Pendekatan per lokasi lebih unggul di Jawa Timur karena heterogenitas iklim antar sentra padi (Bojonegoro vs Ngawi) [8], [26].

Dalam penelitian ini, kalibrasi per lokasi diterapkan pada output TFT untuk meningkatkan reliabilitas prediksi probabilistik. Hal ini memastikan bahwa probabilitas kekeringan berat ( $SPEI < -1.5$ ) sesuai dengan realitas lapangan, sehingga sistem peramalan lebih actionable bagi pemangku kepentingan pertanian [25], [26].

### 2.2.6 Temporal Fusion Transformer (TFT)

Temporal Fusion Transformer (TFT) adalah arsitektur deep learning yang dirancang khusus untuk peramalan time series multi-horizon dengan struktur input heterogen dan kebutuhan interpretabilitas tinggi. Model ini menggabungkan mekanisme attention, gating, dan variable selection untuk menangani kompleksitas data iklim, sehingga sangat sesuai sebagai metode utama dalam penelitian ini untuk meramalkan SPEI-3 [24].

Dalam konteks kekeringan pertanian padi di Jawa Timur, TFT memungkinkan integrasi variabel statis (lokasi kabupaten), known future (musim), dan observed variables (presipitasi,  $ET_0$ , suhu, kelembaban tanah) dalam satu kerangka. Kemampuan ini mendukung peramalan probabilistik multi-horizon yang akurat dan interpretable, sehingga dapat menjadi dasar sistem peringatan dini yang andal [24], [30].

#### 2.2.6.1 Tujuan Desain dan Keunggulan TFT

TFT dirancang untuk mengatasi keterbatasan model deep learning konvensional seperti LSTM yang cenderung black-box dan kurang optimal pada multi-horizon forecasting. Tujuannya adalah menghasilkan prediksi yang akurat sekaligus menyediakan interpretabilitas bawaan melalui variable selection dan attention mechanism [24].

Salah satu komponen penting adalah fungsi kerugian berbasis quantile:

$$L(\tau) = \sum_i [\tau(y_i - \hat{y}_i)1_{\{y_i \geq \hat{y}_i\}} + (1 - \tau)(\hat{y}_i - y_i)1_{\{y_i < \hat{y}_i\}}] \quad (2.1)$$

di mana  $\tau$  adalah quantile yang diinginkan (misalnya 0.1, 0.5, 0.9). Fungsi ini memungkinkan TFT menghasilkan P10, P50, dan P90 secara simultan [24].

Keunggulan utama TFT adalah kemampuannya menangani input heterogen dan menghasilkan quantile output dengan stabilitas performa yang baik pada horizon yang lebih panjang. Dalam penerapan pada SPEI-3, model ini mampu

memprediksi lintasan kekeringan hingga 30 hari dengan reliabilitas tinggi di wilayah heterogen seperti sentra padi Jawa Timur [24], [30].

The figure illustrates the architecture of the proposed model, divided into three main components: Temporal Fusion Decoder, Gated Residual Network (GRN), and Variable Selection Network.

**Temporal Fusion Decoder:** This section processes static metadata and past inputs. It starts with a Variable Selection block and a Static Metadata Encoder. The past inputs ( $X_{t-k}$  to  $X_t$ ) are processed by a Variable Selection block and an LSTM Encoder. The outputs are combined in an Add & Norm Gate. The static metadata is processed by a Static Covariate Encoder. The outputs of the LSTM Encoder and the Static Covariate Encoder are combined in another Add & Norm Gate. The result is then processed by a GRN block. The GRN block is part of a larger structure that includes a Masked Interpretable Multi-head Attention mechanism. The outputs of the GRN block are combined in an Add & Norm Gate. The result is then processed by a GRN block. The GRN block is part of a larger structure that includes a Masked Interpretable Multi-head Attention mechanism. The outputs of the GRN block are combined in an Add & Norm Gate. The result is then processed by a GRN block.

**Gated Residual Network (GRN):** This section further refines the outputs. It consists of a series of Add & Norm, Dense, and GRN blocks. The outputs of the GRN block are combined in an Add & Norm Gate. The result is then processed by a GRN block. The GRN block is part of a larger structure that includes a Masked Interpretable Multi-head Attention mechanism. The outputs of the GRN block are combined in an Add & Norm Gate. The result is then processed by a GRN block.

**Variable Selection Network:** This section uses a Softmax layer to select relevant features. It takes transformed inputs (Linear/Embedding) and external context (Optical) as input. The outputs are combined in an Add & Norm Gate. The result is then processed by a GRN block. The GRN block is part of a larger structure that includes a Masked Interpretable Multi-head Attention mechanism. The outputs of the GRN block are combined in an Add & Norm Gate. The result is then processed by a GRN block.

Arsitektur TFT dimulai dengan Variable Selection Network (VSN) yang secara adaptif memilih variabel paling relevan pada setiap time step. VSN menghitung bobot pentingnya fitur melalui soft-max pada skor yang dihasilkan dari GRN:

$$v = \text{softmask}(GRN(x)) \quad (2.2)$$

dengan  $v$  sebagai bobot variabel. Komponen ini sangat penting untuk data multivariat SPEI-3 karena mampu memprioritaskan  $ET_0$ , presipitasi, dan kelembaban tanah di antara variabel lain, sehingga meningkatkan efisiensi dan interpretabilitas model [24].

Selanjutnya, *Gated Residual Network* (GRN) berfungsi sebagai blok feed-forward dengan mekanisme gating untuk mengontrol aliran informasi:

$$GRN(x) = Linear(ReLU(Linear(x))) \odot \sigma(Linear(x)) \quad (2.3)$$

di mana  $\odot$  adalah perkalian elemen-wise dan  $\sigma$  adalah sigmoid. GRN membantu menjaga stabilitas pembelajaran dan menonaktifkan komponen yang tidak relevan, terutama saat memproses data iklim yang noisy di Jawa Timur [24].

Bagian LSTM *encoder-decoder* menangani dinamika temporal jangka pendek hingga menengah. LSTM encoder memproses observed inputs historis, sementara decoder mengintegrasikan informasi tersebut dengan known future inputs. Kombinasi ini memungkinkan pemodelan pola musiman yang dominan di sentra padi Jawa Timur [24], [30].

#### 2.2.6.3 Penanganan Berbagai Jenis Input, Multi-Horizon, Quantile Output, dan Interpretabilitas

TFT secara eksplisit memisahkan penanganan tiga jenis input: static (lokasi), known future (kalender musim), dan observed (variabel iklim historis). Penerapan ini memungkinkan model memanfaatkan informasi spasial heterogen di lima sentra padi Jawa Timur untuk meningkatkan akurasi lokal [24], [30].

Pada bagian multi-horizon, TFT menghasilkan prediksi hingga 30 hari secara simultan dengan quantile output. Prediction interval yang dihasilkan (misalnya P10–P90) merepresentasikan rentang nilai di mana sekitar 80% kemungkinan SPEI-3 akan berada, sehingga dapat digunakan untuk menilai risiko kekeringan berat ( $\text{SPEI} < -1.5$ ) pada fase kritis tanaman padi [24], [25].

Interpretabilitas menjadi keunggulan utama melalui VSN (*feature importance*) dan *interpretable multi-head self-attention* dengan rumus:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_K}}\right)V \quad (2.4)$$

Mekanisme ini menangkap dependensi jangka panjang dan pola musiman. Analisis attention weights memungkinkan peneliti mengidentifikasi variabel dominan (misalnya ETo atau kelembaban tanah) dan periode historis yang paling berpengaruh terhadap prediksi kekeringan, sehingga meningkatkan kepercayaan pemangku kepentingan [24], [30].

#### 2.2.7 Pengembangan Web Visualisasi Data Menggunakan Vue.js dan FastAPI

Website visualisasi data merupakan media penyajian hasil analitik yang mengubah keluaran model menjadi informasi yang dapat dipahami pengguna. Dalam penelitian peramalan kekeringan, antarmuka web berfungsi menyajikan prediksi SPEI-3, rentang ketidakpastian P10-P90, status kategori kekeringan, serta perbandingan antarwilayah secara terstruktur. Pemisahan antara antarmuka

pengguna dan layanan pengolahan data diperlukan agar visualisasi dapat dikembangkan tanpa mengubah pipeline komputasi peramalan. Pendekatan tersebut relevan untuk sistem pendukung keputusan karena pengguna dapat mengakses hasil prediksi melalui representasi tabel, grafik deret waktu, dan indikator kondisi tanpa berinteraksi langsung dengan kode model.

Vue.js merupakan framework JavaScript untuk membangun antarmuka pengguna berbasis komponen dan reaktivitas data. Arsitektur berbasis komponen memungkinkan elemen visualisasi, seperti pemilih wilayah, kartu indikator SPEI, grafik prediksi, dan tabel ringkasan, dikembangkan sebagai bagian yang terpisah tetapi tetap dapat digunakan bersama dalam satu dashboard. Sifat reaktif Vue.js membuat perubahan data dari API dapat diperbarui pada tampilan secara konsisten, sehingga sesuai untuk menyajikan hasil peramalan yang berubah menurut kota, tanggal, dan horizon prediksi. Studi perbandingan framework front-end menunjukkan bahwa Vue.js menyediakan struktur pengembangan antarmuka yang ringkas dan sesuai untuk pengembangan website berbasis JavaScript [34].

FastAPI merupakan framework layanan web berbasis Python yang dapat digunakan untuk membangun API sebagai penghubung antara dashboard dan keluaran pipeline analitik. Dalam rancangan ini, FastAPI bertugas menyediakan endpoint untuk memperoleh data prediksi, interval kuantil, kategori SPEI, dan informasi interpretabilitas dalam format JSON. Vue.js kemudian mengonsumsi endpoint tersebut untuk membangun visualisasi pada sisi klien. Pemisahan tanggung jawab ini menjaga proses inferensi TFT, pengolahan data, dan penyajian antarmuka tetap modular; perubahan pada satu lapisan tidak secara langsung mengharuskan perubahan pada lapisan lainnya. Penerapan gabungan FastAPI dan Vue pada sistem pemodelan atmosfer menunjukkan kelayakan arsitektur tersebut untuk mengintegrasikan layanan komputasi dengan visualisasi web [35].

Penggunaan Vue.js dan FastAPI pada penelitian ini didasarkan pada kebutuhan dashboard yang informatif, modular, dan mudah dikembangkan. Vue.js digunakan pada lapisan presentasi untuk menampilkan informasi peramalan secara interaktif, sedangkan FastAPI digunakan pada lapisan layanan untuk menyalurkan hasil model secara terstandar melalui API. Dengan arsitektur tersebut, dashboard tidak melakukan pelatihan ulang model, melainkan menyajikan artefak prediksi

yang dihasilkan pipeline penelitian. Batasan ini menjaga konsistensi hasil yang ditampilkan dengan hasil evaluasi model serta mendukung reproduktibilitas proses analisis.

### **2.3 Analisis Celah Penelitian**

Landasan teori pada subbab sebelumnya telah menjelaskan secara mendalam konsep kekeringan pertanian, indeks SPEI, karakteristik time series iklim, multi-horizon forecasting, peramalan probabilistik, serta arsitektur Temporal Fusion Transformer. Sintesis tersebut menunjukkan bahwa meskipun telah banyak kemajuan dalam pemantauan dan peramalan kekeringan, masih terdapat kesenjangan yang signifikan antara teori yang ada dengan kebutuhan praktis peramalan SPEI-3 multi-horizon yang probabilistik, interpretable, dan kontekstual di sentra padi Jawa Timur. Analisis celah penelitian ini bertujuan untuk mengidentifikasi kekurangan tersebut secara sistematis agar posisi dan kontribusi penelitian ini menjadi jelas.

#### **2.3.1 Sintesis Temuan Penelitian Terdahulu**

Penelitian terdahulu menunjukkan perkembangan signifikan dalam pemantauan dan peramalan kekeringan pertanian. Indeks SPEI terbukti lebih unggul dibandingkan SPI karena memasukkan evapotranspirasi potensial ( $ET_0$ ), sehingga lebih sensitif terhadap perubahan iklim dan dampak pada tanaman padi [8], [10], [15]. Pada tataran metodologi, model statistik tradisional seperti ARIMA memiliki keterbatasan dalam menangani data non-linear dan non-stasioner, sedangkan pendekatan hybrid (ARIMA-LSTM, XGBoost) serta deep learning (LSTM, Informer, S-Transformer) berhasil meningkatkan akurasi peramalan SPEI pada berbagai skala waktu [12], [14], [17], [20].

Beberapa studi juga telah menerapkan multi-horizon forecasting dan pendekatan probabilistik, meskipun masih terbatas. Temporal Fusion Transformer (TFT) menonjol karena kemampuannya menghasilkan prediksi multi-horizon yang interpretable melalui Variable Selection Network dan temporal attention [24]. Di tingkat regional, penelitian di Jawa Timur telah memetakan kerentanan kekeringan lahan padi, terutama di Bojonegoro, Lamongan, Ngawi, dan Tuban, yang sering mengalami penurunan produksi akibat kekeringan musiman [33].

### **2.3.2 Celah Metodologis**

Meskipun terdapat kemajuan, beberapa celah metodologis masih teridentifikasi. Pertama, sebagian besar penelitian peramalan SPEI masih menggunakan pendekatan single-step atau recursive, sehingga kurang mampu memodelkan lintasan prediksi multi-horizon secara simultan dan konsisten [12], [17]. Kedua, prediksi deterministik masih mendominasi, padahal ketidakpastian iklim memerlukan output probabilistik berbasis quantile untuk mendukung pengambilan keputusan berbasis risiko [25], [26].

Ketiga, interpretabilitas model masih menjadi tantangan. Model LSTM dan XGBoost sering diperlakukan sebagai black-box, sedangkan TFT yang menyediakan VSN dan attention weights belum banyak diterapkan pada SPEI-3 untuk kekeringan pertanian [24]. Keempat, kalibrasi probabilistik per lokasi masih jarang dilakukan, padahal heterogenitas iklim di Jawa Timur menuntut penyesuaian spasial agar reliabilitas prediksi meningkat [8], [26].

### **2.3.3 Celah Operasional dan Kontekstual**

Pada tingkat operasional, penelitian di Indonesia dan Jawa Timur sebagian besar bersifat deskriptif atau pemetaan kerentanan, belum mengintegrasikan peramalan multi-horizon probabilistik dengan interpretabilitas untuk mendukung sistem peringatan dini di tingkat petani [33]. Studi kontekstual di sentra padi Jawa Timur juga masih terbatas dalam menghubungkan SPEI-3 dengan deteksi kekeringan parah ( $\text{SPEI} < -1.5$ ) dan pemanfaatan dashboard untuk visualisasi hasil prediksi.

### **2.3.4 Posisi dan Kontribusi Penelitian**

Penelitian ini mengisi celah tersebut dengan mengimplementasikan Temporal Fusion Transformer untuk peramalan multi-horizon SPEI-3 secara probabilistik (quantile P10, P50, P90) pada lima sentra padi Jawa Timur. Kontribusi utamanya meliputi: (1) integrasi simultan multi-horizon forecasting, prediksi probabilistik, kalibrasi per lokasi, dan interpretabilitas bawaan TFT; (2) evaluasi empiris degradasi performa antar-horizon menggunakan data historis 2005–2025; dan (3) penerapan operasional melalui dashboard untuk mendeteksi kekeringan parah dan mendukung pengambilan keputusan di tingkat petani serta pemerintah daerah.




Dengan demikian, penelitian ini tidak hanya mengisi kesenjangan metodologis, tetapi juga memberikan kontribusi praktis bagi ketahanan pangan di Jawa Timur.

## BAB III

### METODE PENELITIAN

#### 3.1 Tahapan Penelitian

Penelitian ini dilaksanakan melalui serangkaian tahapan yang sistematis dan terintegrasi untuk mengembangkan sistem peramalan multi-horizon kekeringan lahan pertanian berbasis SPEI-3 menggunakan Temporal Fusion Transformer (TFT). Tahapan penelitian dirancang secara berurutan mulai dari studi literatur hingga analisis interpretabilitas, dengan pendekatan spasial-temporal yang melibatkan pembentukan super-node. Alur keseluruhan tahapan penelitian disajikan pada Gambar 3.1



Gambar 3.1 Alur Tahapan Penelitian

Tahap pertama adalah studi literatur yang difokuskan pada tinjauan metodologis untuk mendukung desain penelitian, khususnya penggunaan data Open-Meteo Archive API berbasis ERA5, pendekatan multi-node agregasi menjadi super-node, komputasi SPEI-3 dengan resolusi harian, penerapan Temporal Fusion Transformer (TFT) untuk peramalan multi-horizon probabilistik, serta pengembangan dashboard visualisasi. Tinjauan ini menjadi dasar justifikasi ilmiah terhadap pilihan metode yang digunakan.

Tahap pengumpulan data dilakukan dengan mengambil data iklim harian periode 2005-2025 dari Open-Meteo Archive API pada lima sentra padi di Jawa Timur. Setiap kota direpresentasikan oleh sembilan kandidat node spasial untuk memperoleh cakupan kondisi iklim di sekitar pusat wilayah.

Tahap preprocessing mencakup validasi struktur data, penanganan nilai hilang menggunakan forward fill per node, seleksi lima node paling representatif berbasis hybrid scoring, serta agregasi node terpilih menjadi super-node. Tahap ini dilakukan untuk menghasilkan data yang konsisten, representatif, dan bebas kebocoran informasi temporal.

Tahap komputasi indeks SPEI menghitung defisit air dari presipitasi dan evapotranspirasi potensial, melakukan akumulasi bergerak selama 90 hari, serta mentransformasikan hasilnya menjadi SPEI-3. Selanjutnya, fitur hidroklimat dan temporal disusun menjadi dataset time series dengan encoder 90 hari dan horizon prediksi 30 hari.

Tahap perancangan dan pelatihan model membangun Temporal Fusion Transformer dengan keluaran kuantil P10, P50, dan P90. Pelatihan menggunakan pembagian data kronologis, sedangkan validasi digunakan untuk memilih model terbaik dan mengkalibrasi interval prediksi per kota.

Tahap peramalan menghasilkan prediksi SPEI-3 multi-horizon pada data uji. Tahap evaluasi kemudian mengukur akurasi, hubungan prediksi dengan data aktual, dan kualitas interval probabilistik menggunakan RMSE, MAE,  $R^2$ , korelasi Pearson, serta PICP, disertai perbandingan terhadap naive persistence baseline. Tahap terakhir adalah analisis interpretabilitas melalui Variable Selection Network dan temporal attention untuk mengidentifikasi kontribusi variabel serta informasi historis yang berpengaruh terhadap prediksi.

### **3.2 Pengumpulan Data**

Tahap awal dalam penelitian ini adalah proses pengumpulan data iklim yang digunakan sebagai dasar pembentukan indeks kekeringan dan pemodelan peramalan deret waktu. Data yang digunakan berupa data sekunder multivariat dengan resolusi temporal harian yang diperoleh dari layanan Open-Meteo Archive API. Pemanfaatan data iklim historis dengan cakupan periode panjang dilakukan untuk memungkinkan model mempelajari pola musiman, variabilitas iklim tahunan,

serta dinamika kekeringan yang berkembang secara temporal. Penggunaan data harian juga dipilih karena lebih mampu merepresentasikan perubahan kondisi hidroklimat secara rinci dibandingkan data agregasi bulanan sehingga lebih sesuai untuk kebutuhan peramalan multi-horizon jangka pendek.

Wilayah penelitian difokuskan pada lima kabupaten di Provinsi Jawa Timur yang memiliki karakteristik agroklimat penting terhadap risiko kekeringan, yaitu Bojonegoro, Lamongan, Nganjuk, Ngawi, dan Tuban. Pemilihan wilayah tersebut didasarkan pada representasi kawasan pertanian dan kerentanan terhadap fluktuasi kondisi iklim musiman di wilayah Jawa Timur. Setiap wilayah direpresentasikan menggunakan koordinat pusat kota yang kemudian digunakan sebagai acuan dalam proses pembentukan node spasial pada tahap selanjutnya. Informasi koordinat pusat wilayah penelitian ditunjukkan pada Tabel 3.1.

Tabel 3.1 Koordinat Pusat Wilayah Penelitian

| No | Wilayah    | Latitude | Longitude |
|----|------------|----------|-----------|
| 1  | Bojonegoro | -7.155   | 111.880   |
| 2  | Lamongan   | -7.128   | 112.316   |
| 3  | Nganjuk    | -7.604   | 111.905   |
| 4  | Ngawi      | -7.403   | 111.445   |
| 5  | Tuban      | -6.895   | 112.045   |

Sumber data iklim pada penelitian ini berasal dari Open-Meteo Archive API yang menyediakan data meteorologi historis berbasis reanalysis dan observasi numerik cuaca. Data diambil menggunakan zona waktu Asia/Jakarta agar konsisten dengan kondisi temporal wilayah penelitian. Variabel utama yang digunakan meliputi curah hujan harian, evapotranspirasi, kelembapan tanah lapisan atas, suhu maksimum harian, dan suhu minimum harian. Variabel-variabel tersebut dipilih karena memiliki keterkaitan langsung terhadap pembentukan neraca air dan kondisi kekeringan meteorologis yang direpresentasikan oleh indeks SPEI-3. Variabel yang menjadi parameter dalam penelitian ini ditunjukkan dengan lengkap pada tabel 3.2

Tabel 3.2 Parameter Penelitian

| No | Parameter          | Deskripsi                                         | Nama Parameter pada Dataset |
|----|--------------------|---------------------------------------------------|-----------------------------|
| 1  | Presipitasi Harian | Total curah hujan yang jatuh dalam satu hari (mm) | precipitation_sum           |

| No | Parameter                     | Deskripsi                                                                                           | Nama Parameter pada Dataset |
|----|-------------------------------|-----------------------------------------------------------------------------------------------------|-----------------------------|
| 2  | Evapotranspirasi              | Jumlah air yang menguap dari permukaan tanah dan tanaman per hari (mm/hari)                         | et0_fao_evapotranspiration  |
| 3  | Suhu Maksimum                 | Suhu udara tertinggi yang tercatat dalam satu hari (°C)                                             | temperature_2m_max          |
| 4  | Suhu Minimum                  | Suhu udara terendah yang tercatat dalam satu hari (°C)                                              | temperature_2m_min          |
| 5  | Kelembaban Tanah Lapisan Atas | Kadar air rata-rata di lapisan tanah atas yang memengaruhi akar tanaman ( $\text{m}^3/\text{m}^3$ ) | soil_moisture               |
| 6  | Kelembaban Udara              | Persentase kelembaban udara rata-rata dalam satu hari (%)                                           | relative_humidity_2m_mean   |
| 7  | Radiasi Gelombang Pendek      | Jumlah energi radiasi matahari yang diterima permukaan tanah per hari ( $\text{MJ}/\text{m}^2$ )    | shortwave_radiation_sum     |
| 8  | Kecepatan Angin               | Kecepatan rata-rata angin di ketinggian 10 meter (km/jam)                                           | wind_speed_10m_mean         |

Data iklim yang diperoleh kemudian disusun dalam bentuk deret waktu harian dengan rentang periode 1 Januari 2005 hingga 1 Januari 2026. Struktur data tersebut memungkinkan proses analisis temporal dilakukan secara kronologis sehingga sesuai dengan kebutuhan model peramalan berbasis *deep learning*. Selain itu, penggunaan data historis jangka panjang bertujuan untuk meningkatkan kemampuan model dalam mempelajari pola musiman, anomali iklim, serta karakteristik kekeringan pada berbagai kondisi hidroklimat.

Pada tahap pengumpulan data, setiap wilayah penelitian tidak direpresentasikan hanya dengan satu titik koordinat tunggal, tetapi melalui pembentukan beberapa kandidat node spasial di sekitar pusat wilayah. Pendekatan ini digunakan untuk meningkatkan representasi spasial data iklim dan mengurangi pengaruh noise lokal pada satu titik observasi. Pembentukan node dilakukan menggunakan pola grid berbasis offset koordinat tetap yang tersebar di sekitar pusat kota.

Pendekatan multi-node tersebut digunakan untuk mendukung pembentukan representasi super-node pada tahap preprocessing sehingga data yang digunakan dalam pemodelan lebih stabil dan representatif terhadap kondisi wilayah penelitian secara spasial. Dengan demikian, proses pengumpulan data tidak hanya berfungsi memperoleh data historis iklim, tetapi juga membangun fondasi spasial-temporal yang mendukung proses peramalan kekeringan berbasis Temporal Fusion Transformer secara lebih robust.

### 3.3 Preprocessing Data

Tahap preprocessing data dilakukan untuk memastikan bahwa data iklim yang digunakan dalam penelitian memiliki kualitas, konsistensi temporal, dan struktur yang sesuai dengan kebutuhan pemodelan deret waktu berbasis *deep learning*. Pada penelitian ini, preprocessing merupakan tahapan yang sangat penting karena kualitas data masukan akan secara langsung memengaruhi kemampuan model Temporal Fusion Transformer dalam mempelajari pola temporal dan menghasilkan prediksi yang stabil. Selain itu, preprocessing juga dirancang untuk mencegah terjadinya *data leakage*, yaitu kondisi ketika informasi masa depan secara tidak langsung masuk ke dalam proses pelatihan model sehingga menyebabkan hasil evaluasi menjadi bias.

Tahap preprocessing dilakukan pada level node individual terlebih dahulu sebelum proses agregasi spasial dilakukan. Pendekatan ini dipilih agar karakteristik temporal masing-masing node tetap terjaga dan proses seleksi node dapat dilakukan secara objektif berdasarkan perilaku data historis setiap titik spasial. Secara umum, preprocessing terdiri atas beberapa tahapan utama, yaitu validasi struktur data, penanganan nilai hilang (*missing value*), penyusunan urutan temporal, seleksi node spasial, agregasi super-node, *feature engineering*, dan pemeriksaan kualitas data akhir. Alur tahapan dari preprocessing data ditunjukkan pada gambar 3.2



Gambar 3.2 Flowchart Preprocessing Data

Tahap pertama dalam preprocessing adalah validasi struktur dan konsistensi data mentah (*raw dataset*). Sistem melakukan pemeriksaan terhadap keberadaan atribut wajib seperti identitas wilayah, identitas node, waktu pengamatan, koordinat spasial, serta variabel iklim utama. Pemeriksaan ini bertujuan untuk memastikan bahwa seluruh data yang diproses memiliki format yang seragam dan sesuai dengan kebutuhan pipeline penelitian. Selain itu, validasi juga dilakukan untuk memastikan urutan waktu bersifat kronologis sehingga data dapat diproses sebagai deret waktu kontinu.

Tahap berikutnya adalah penanganan nilai hilang (*missing value*). Pada penelitian ini, penanganan missing value dilakukan menggunakan metode *forward fill* pada setiap node secara independen. Pendekatan *forward fill* dilakukan dengan mengisi nilai yang hilang menggunakan nilai valid terakhir pada urutan waktu sebelumnya. Metode ini dipilih karena lebih sesuai untuk data time series dibandingkan interpolasi acak yang berpotensi menyebabkan kebocoran informasi temporal dari masa depan ke masa lalu.

Secara matematis, proses *forward fill* dapat dinyatakan sebagai berikut:

$$x_t = x_t - 1 \quad (3.1)$$

dengan:

- $x_t$  = nilai variabel pada waktu ke- $t$

- $x_t - 1$  = nilai valid sebelumnya pada deret waktu

Pendekatan ini mempertahankan kontinuitas temporal data sekaligus menjaga integritas urutan informasi historis yang digunakan oleh model.

Setelah proses penanganan missing value dilakukan, data kemudian disusun berdasarkan urutan waktu untuk memastikan setiap node memiliki sequence temporal yang konsisten. Penyusunan urutan waktu ini sangat penting dalam pembentukan dataset *encoder-decoder* pada model TFT karena model mempelajari pola berdasarkan keterurutan data historis. Kesalahan urutan temporal dapat menyebabkan distorsi pola musiman dan menurunkan performa model secara signifikan.

Tahap preprocessing selanjutnya adalah proses seleksi node spasial yang digunakan untuk membentuk representasi *super-node*. Setiap wilayah penelitian awalnya direpresentasikan oleh sembilan kandidat node spasial yang tersebar di sekitar pusat wilayah. Namun, tidak seluruh node digunakan dalam pemodelan. Sistem melakukan proses seleksi terhadap node-node tersebut untuk memilih titik yang paling representatif terhadap karakteristik wilayah secara keseluruhan.

Seleksi node dilakukan menggunakan pendekatan *hybrid scoring* yang mempertimbangkan dua komponen utama, yaitu kesamaan perilaku data iklim (*behavior similarity*) dan kedekatan spasial terhadap pusat wilayah (*distance score*). Komponen behavior similarity dihitung menggunakan rerata korelasi antar variabel cuaca antara suatu node dengan profil wilayah pembanding. Sementara itu, distance score dihitung berdasarkan jarak geografis node terhadap pusat wilayah penelitian.

Bobot yang lebih besar pada behavior score diberikan karena penelitian ini lebih menekankan kesamaan pola temporal iklim dibanding sekadar kedekatan geografis. Berdasarkan skor tersebut, dipilih lima node terbaik pada setiap wilayah untuk kemudian diagregasikan menjadi satu entitas spasial yang disebut *super-node*.


Proses agregasi super-node dilakukan dengan menghitung nilai rata-rata variabel iklim dari node-node terpilih pada setiap waktu pengamatan. Agregasi ini bertujuan untuk mengurangi noise lokal pada satu titik observasi serta meningkatkan representasi kondisi iklim wilayah secara lebih stabil. Secara konseptual, agregasi super-node dapat dinyatakan sebagai:



$$SN_t = \frac{1}{n} \sum_{i=1}^n x_{i,t} \quad (3.2)$$

dengan:

- $SN_t$  = nilai super-node pada waktu ke- $t$
- $x_{i,t}$  = nilai node ke- $i$  pada waktu ke- $t$
- $n$  = jumlah node terpilih



Gambar 3.3 Visualisasi Lima Node Terpilih pada Setiap Wilayah Penelitian

Gambar 3.3 menunjukkan hasil seleksi lima node spasial pada masing-masing wilayah penelitian, yaitu Bojonegoro, Lamongan, Nganjuk, Ngawi, dan Tuban. Node yang ditampilkan pada gambar merupakan node terpilih yang digunakan dalam proses agregasi super-node. Pembatasan menjadi lima node per wilayah bertujuan mengurangi pengaruh noise lokal dari satu titik pengamatan, sekaligus mempertahankan representasi spasial kondisi hidroklimat di sekitar sentra padi. Kelima node tersebut kemudian diagregasikan per waktu pengamatan untuk membentuk satu super-node pada setiap kota sebagai masukan model Temporal Fusion Transformer.

Setelah agregasi super-node dilakukan, tahap preprocessing dilanjutkan dengan *feature engineering* untuk menghasilkan fitur-fitur tambahan yang mendukung kemampuan model dalam mengenali pola temporal dan musiman. Feature engineering ini dilakukan untuk meningkatkan kemampuan representasi data terhadap dinamika hidroklimat yang bersifat nonlinier dan musiman.

Tahap akhir preprocessing adalah proses *quality checking* untuk memastikan tidak terdapat duplikasi data, ketidaksesuaian jumlah node, nilai tak terhingga (*infinite value*), maupun inkonsistensi struktur dataset. Data yang telah lolos proses preprocessing kemudian digunakan pada tahap pembentukan dataset time series untuk kebutuhan pelatihan model Temporal Fusion Transformer.

### 3.4 Komputasi Indeks SPEI

Tahap awal dalam komputasi SPEI adalah menghitung defisit air (*water deficit*), yaitu selisih antara curah hujan harian dan evapotranspirasi potensial. Defisit air digunakan untuk menggambarkan keseimbangan antara suplai air dari presipitasi dan kehilangan air akibat proses evapotranspirasi. Nilai defisit air negatif menunjukkan bahwa kehilangan air lebih besar dibandingkan suplai air sehingga mengindikasikan kecenderungan kondisi kering. Perhitungan defisit air dinyatakan menggunakan persamaan berikut:

$$D_t = P_t - PET_t \quad (3.3)$$

dengan:

- $D_t$  = defisit air pada waktu ke- $t$
- $P_t$  = curah hujan harian
- $PET_t$  = evapotranspirasi potensial harian

Nilai defisit air yang telah diperoleh kemudian diakumulasikan menggunakan pendekatan *rolling window* untuk membentuk indeks SPEI skala tiga bulan. Karena penelitian ini menggunakan data dengan resolusi harian, maka skala tiga bulan direpresentasikan sebagai akumulasi bergerak selama 90 hari. Pendekatan rolling accumulation digunakan untuk menangkap efek kumulatif kondisi surplus maupun defisit air yang berkembang secara gradual dalam suatu periode waktu. Akumulasi rolling SPEI dinyatakan sebagai berikut:

$$X_t^{(k)} = \sum_{i=0}^{k \times 30 - 1} D_{t-i} \quad (3.4)$$

dengan:

- $X_t^{(k)}$  = akumulasi defisit air skala  $k$  bulan pada waktu ke- $t$
- $D_{t-1}$  = defisit air pada waktu sebelumnya
- $k$  = skala SPEI yang digunakan

Pada penelitian ini digunakan nilai  $k = 3$  sehingga proses rolling accumulation dilakukan selama 90 hari sesuai dengan karakteristik indeks SPEI-3.

Setelah proses akumulasi dilakukan, distribusi nilai defisit air ditransformasikan ke dalam distribusi probabilitas *log-logistic* (*Fisk distribution*). Distribusi tersebut kemudian dikonversi menjadi nilai normal baku sehingga menghasilkan nilai SPEI yang terstandarisasi. Transformasi ini memungkinkan interpretasi tingkat kekeringan dilakukan secara konsisten antarperiode waktu dan antar-wilayah penelitian. Transformasi SPEI secara umum dapat dinyatakan sebagai:

$$SPEI_t = \Phi^{-1} \left( F_{fisk} \left( X_t^{(k)} \right) \right) \quad (3.5)$$

dengan:

- $SPEI_t$  = nilai SPEI pada waktu ke- $t$
- $F_{fisk}$  = fungsi distribusi kumulatif log-logistic
- $\Phi^{-1}$  = inverse cumulative distribution function distribusi normal

Nilai SPEI yang dihasilkan memiliki interpretasi bahwa nilai negatif menunjukkan kondisi kering, sedangkan nilai positif menunjukkan kondisi basah. Semakin kecil nilai SPEI, maka tingkat kekeringan yang terjadi semakin tinggi. Interpretasi umum nilai SPEI ditunjukkan pada Tabel 3.3.

Tabel 3.3 Kategori Indeks SPEI

| Rentang Nilai SPEI | Kategori Kondisi   |
|--------------------|--------------------|
| > 2.0              | Kelembapan Ekstrem |
| 1.5 hingga 2.0     | Kelembapan Parah   |
| 1.0 hingga 1.49    | Kelembapan Sedang  |
| 0.51 hingga 0.99   | Kelembapan Ringan  |
| -0.5 hingga 0.5    | Normal             |

|                    |                    |
|--------------------|--------------------|
| -0.51 hingga -0.99 | Kekeringan Ringan  |
| -1.0 hingga -1.49  | Kekeringan Sedang  |
| -1.5 hingga -2.0   | Kekeringan Parah   |
| < -2.0             | Kekeringan Ekstrem |

Contoh perhitungan komputasi nilai SPEI menggunakan data sampel. Didapatkan defisit hariannya adalah  $0,8 - 4,53 = -3,73 \text{ mm}$ . Untuk ilustrasi jendela 90 hari, total defisit 80 hari sebelumnya didapatkan sebesar  $-100,00 \text{ mm}$  dan total 10 hari terakhir sebesar  $-41,99 \text{ mm}$ , sehingga akumulasi menjadi  $-141,99 \text{ mm}$ . Jika distribusi Fisk menghasilkan probabilitas kumulatif 0,0668, transformasi normal baku menghasilkan  $SPEI = -1,50$ . Berdasarkan Tabel 3.3 nilai ini menunjukkan kondisi pada batas Kekeringan Parah. Pehitungan ini juga ditunjukan pada Tabel 3.4

Tabel 3.4 Contoh Komputasi Nilai SPEI

| Input                                                                                     | Hasil                      | Interpretasi           |
|-------------------------------------------------------------------------------------------|----------------------------|------------------------|
| $P = 0,8 \text{ mm}; PET = 4,53 \text{ mm}$                                               | $D = -3,73 \text{ mm}$     | Defisit air harian     |
| $Akumulasi \text{ 80 hari} = -100,00 \text{ mm}$<br>$10 \text{ hari} = -41,99 \text{ mm}$ | $X^3 = -141,99 \text{ mm}$ | Defisit 90 hari        |
| $F_{fisk}(X^3) = 0,0668$                                                                  | $SPEI = -1,50$             | Batas Kekeringan Parah |

Selain komputasi SPEI, tahap feature engineering juga dilakukan untuk membentuk fitur-fitur tambahan yang mendukung proses pembelajaran model. Salah satu fitur yang dibentuk adalah *SPEI difference*, yaitu perubahan nilai SPEI terhadap waktu sebelumnya. Fitur ini digunakan untuk membantu model mengenali arah perubahan kondisi kekeringan dari waktu ke waktu.

Selain itu, dilakukan pula pembentukan fitur musiman menggunakan transformasi sinus dan kosinus berdasarkan indeks bulan. Pendekatan ini digunakan untuk merepresentasikan pola periodik musiman secara kontinu sehingga model dapat mempelajari siklus tahunan tanpa terjadi diskontinuitas antarbulan.

Transformasi musiman dinyatakan sebagai berikut:

$$Month_{sin} = \sin\left(\frac{2\pi m}{12}\right) \quad (3.6)$$

$$Month_{cos} = \cos\left(\frac{2\pi m}{12}\right) \quad (3.7)$$

dengan  $m$  sebagai indeks bulan. Selain fitur musiman, dilakukan pula transformasi logaritmik terhadap curah hujan menggunakan fungsi logaritma natural. Transformasi ini bertujuan untuk mengurangi pengaruh distribusi curah hujan yang sangat skewed dan membantu model dalam mempelajari pola data secara lebih stabil.

Tahap feature engineering menghasilkan sejumlah fitur temporal dan hidroklimat yang selanjutnya digunakan dalam pembentukan dataset *time series* untuk model Temporal Fusion Transformer. Dengan adanya transformasi dan penambahan fitur tersebut, model diharapkan mampu mempelajari hubungan temporal yang lebih kompleks dan menghasilkan prediksi kondisi kekeringan yang lebih akurat serta stabil pada berbagai horizon waktu.

### 3.5 Pembentukan Dataset Time Series


Setelah proses preprocessing, pembentukan *super-node*, dan feature engineering selesai dilakukan, tahap berikutnya adalah pembentukan dataset *time series* yang akan digunakan sebagai masukan pada model Temporal Fusion Transformer (TFT). Tahap ini bertujuan untuk menyusun data dalam format sekuensial yang sesuai dengan kebutuhan arsitektur encoder-decoder pada model TFT. Pembentukan dataset dilakukan secara terstruktur agar hubungan temporal antarwaktu tetap terjaga serta setiap wilayah penelitian dapat diproses sebagai entitas deret waktu yang independen.

Pada penelitian ini, dataset time series dibentuk menggunakan pendekatan *sequence-to-sequence forecasting*, yaitu model menerima sejumlah data historis sebagai input encoder dan menghasilkan prediksi untuk beberapa horizon waktu ke depan secara simultan. Pendekatan ini memungkinkan model mempelajari pola temporal jangka pendek dan menengah dalam satu proses pelatihan tanpa perlu melakukan prediksi secara iteratif untuk setiap langkah waktu.

Secara umum, struktur dataset pada penelitian ini terdiri atas dua komponen utama, yaitu:

1. *Encoder sequence* sebagai data historis,
2. *Prediction sequence* sebagai horizon prediksi masa depan.

Panjang sequence historis (*encoder length*) yang digunakan adalah 90 hari, sedangkan panjang horizon prediksi (*prediction length*) adalah 30 hari. Pemilihan encoder sepanjang 90 hari dilakukan karena target penelitian menggunakan indeks SPEI-3 yang merepresentasikan akumulasi kondisi hidroklimat selama tiga bulan. Dengan demikian, model diharapkan mampu mempelajari pola temporal yang relevan terhadap pembentukan kondisi kekeringan. Ilustrasi struktur encoder dan prediction window dapat ditunjukkan pada Gambar 3.3.



Gambar 3.4 Struktur Encoder dan Prediction Window pada Dataset Time Series

Secara konseptual, pembentukan sequence time series dapat direpresentasikan sebagai:

$$X = \{x_{t-89}, x_{t-88}, \dots, x_t\} \quad (3.8)$$

$$Y = \{y_{t+1}, y_{t+2}, \dots, y_{t+30}\} \quad (3.9)$$

dengan:

- $X$  = sequence historis encoder
- $Y$  = sequence target prediksi
- $x_t$  = fitur input pada waktu ke-ttt
- $y_t$  = target prediksi SPEI pada waktu ke-ttt

Dalam pembentukan dataset, setiap wilayah penelitian diperlakukan sebagai grup deret waktu yang berbeda menggunakan atribut *group id*. Pada penelitian ini, identitas grup ditentukan berdasarkan *super\_node\_id* sehingga setiap sequence antarwilayah tetap terpisah dan tidak terjadi pencampuran informasi temporal antar kota. Pendekatan ini penting untuk menjaga integritas spasial-temporal selama proses pelatihan model.

Selain pengelompokan sequence, fitur input pada dataset juga dibagi ke dalam beberapa kategori sesuai dengan kebutuhan arsitektur TFT, yaitu:

1. *Static categorical features*,
2. *Static real features*,
3. *Time-varying known features*,
4. *Time-varying unknown features*.

Fitur statis kategorikal digunakan untuk merepresentasikan identitas wilayah yang tidak berubah terhadap waktu. Pada penelitian ini, fitur tersebut terdiri atas identitas super-node dan identitas wilayah penelitian. Sementara itu, fitur statis numerik terdiri atas atribut spasial seperti elevasi, latitude, dan longitude yang digunakan untuk membantu model memahami karakteristik geografis masing-masing wilayah.

Fitur temporal yang diketahui di masa depan (*time-varying known features*) terdiri atas indeks waktu dan representasi musiman berbasis sinus-kosinus. Fitur ini tetap tersedia pada horizon prediksi sehingga dapat digunakan model untuk mengenali pola periodik tahunan. Adapun fitur temporal yang tidak diketahui di masa depan (*time-varying unknown features*) terdiri atas variabel hidroklimat dan target historis yang hanya tersedia hingga waktu observasi terakhir.

Untuk menjaga validitas temporal, pembagian dataset dilakukan secara kronologis (*chronological split*) tanpa menggunakan pengacakan data (*random split*). Pendekatan ini digunakan untuk mencegah terjadinya *data leakage* dari periode masa depan ke periode pelatihan. Dataset dibagi menjadi tiga bagian utama, yaitu data pelatihan (*training*), validasi (*validation*), dan pengujian (*testing*).

Data dengan periode sebelum tahun 2023 digunakan sebagai data pelatihan, data tahun 2023 digunakan sebagai data validasi, sedangkan data tahun 2024 dan setelahnya digunakan sebagai data pengujian. Strategi ini dipilih agar evaluasi model lebih merepresentasikan kondisi prediksi nyata pada periode yang belum pernah dilihat model sebelumnya. Ilustrasi pembagian dataset berbasis waktu dapat ditunjukkan pada Gambar 3.4.



Gambar 3.5 Skema Pembagian Dataset Secara Kronologis

Pendekatan chronological split ini menjadi salah satu bagian penting dalam metodologi penelitian karena menjaga integritas evaluasi model pada konteks forecasting deret waktu. Dengan demikian, performa model yang dihasilkan lebih representatif terhadap kondisi implementasi prediksi pada data masa depan yang benar-benar belum diketahui sebelumnya.

Tahap pembentukan dataset time series menghasilkan struktur data final yang siap digunakan dalam proses pelatihan model Temporal Fusion Transformer. Struktur tersebut memungkinkan model memanfaatkan informasi spasial, temporal, dan hidroklimat secara simultan dalam proses pembelajaran pola kekeringan multi-horizon.

### 3.6 Perancangan Model Temporal Fusion Transformer

Model utama yang digunakan dalam penelitian ini adalah *Temporal Fusion Transformer* (TFT), yaitu arsitektur *deep learning* yang dirancang khusus untuk peramalan deret waktu multivariat dengan kemampuan prediksi multi-horizon dan interpretabilitas model. Pemilihan TFT didasarkan pada karakteristik data penelitian yang bersifat multivariat, memiliki dependensi temporal jangka pendek maupun jangka menengah, serta membutuhkan kemampuan menghasilkan prediksi probabilistik untuk merepresentasikan ketidakpastian kondisi kekeringan di masa mendatang.

Berbeda dengan model deret waktu konvensional yang umumnya hanya menghasilkan prediksi titik tunggal (*point forecast*), TFT mampu menghasilkan prediksi berbasis kuantil (*quantile forecasting*) sehingga model tidak hanya mempelajari nilai tengah distribusi, tetapi juga rentang ketidakpastian prediksi. Kemampuan tersebut menjadi penting dalam konteks peramalan kekeringan karena kondisi hidroklimat memiliki tingkat variabilitas dan ketidakpastian yang tinggi.

Selain itu, TFT juga dipilih karena memiliki kemampuan untuk mengintegrasikan berbagai jenis fitur secara simultan, termasuk fitur statis, fitur



temporal yang diketahui di masa depan (*known future inputs*), serta fitur temporal historis. Kemampuan ini memungkinkan model memanfaatkan informasi spasial dan temporal secara lebih komprehensif dibandingkan pendekatan forecasting tradisional.

Secara umum, arsitektur Temporal Fusion Transformer terdiri atas beberapa komponen utama, yaitu:

1. *Variable Selection Network (VSN)*,
2. *LSTM Encoder-Decoder*,
3. *Gating Mechanism*,
4. *Multi-Head Self Attention*,
5. *Quantile Output Layer*.

Komponen pertama dalam TFT adalah *Variable Selection Network (VSN)*, yaitu mekanisme yang berfungsi untuk memilih fitur-fitur yang paling relevan secara adaptif pada setiap langkah waktu. VSN memungkinkan model untuk memfokuskan perhatian pada variabel yang memiliki kontribusi paling besar terhadap prediksi kondisi kekeringan. Pendekatan ini penting karena variabel hidroklimat yang digunakan memiliki tingkat pengaruh yang berbeda-beda terhadap pembentukan nilai SPEI.

Setelah proses seleksi variabel dilakukan, data diproses menggunakan arsitektur *LSTM encoder-decoder*. Bagian encoder bertugas mempelajari pola historis dari sequence input sepanjang 90 hari, sedangkan decoder digunakan untuk menghasilkan prediksi multi-horizon selama 30 hari ke depan. Penggunaan LSTM memungkinkan model menangkap dependensi temporal jangka pendek dan menengah yang berkembang secara berurutan pada data time series.

Secara konseptual, proses encoder–decoder dapat dinyatakan sebagai:

$$h_t = LSTM(x_t, h_{t-1}) \quad (3.10)$$

dengan:

- $x_t$  = input sequence pada waktu ke- $t$
- $h_t$  = hidden state pada waktu ke- $t$

Selain menggunakan LSTM, TFT juga memanfaatkan mekanisme *multi-head self-attention* untuk menangkap dependensi temporal jangka panjang yang sulit dipelajari oleh arsitektur recurrent biasa. Mekanisme attention memungkinkan

model memberikan bobot perhatian lebih besar pada informasi historis tertentu yang dianggap penting terhadap prediksi masa depan.

Mekanisme attention secara umum dapat direpresentasikan sebagai:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_K}}\right)V \quad (3.11)$$

dengan:

- $Q$  = query
- $K$  = key
- $V$  = value
- $d_K$  = dimensi key

Penggunaan attention mechanism memberikan kemampuan interpretabilitas tambahan karena model dapat menunjukkan bagian sequence historis yang paling berpengaruh terhadap prediksi yang dihasilkan.

Pada penelitian ini, model TFT dikonfigurasi menggunakan encoder sepanjang 90 hari dan horizon prediksi sepanjang 30 hari. Konfigurasi tersebut dipilih agar model mampu mempelajari pola temporal yang sesuai dengan karakteristik indeks SPEI-3 yang berbasis akumulasi tiga bulan. Selain itu, model menghasilkan tiga kuantil prediksi, yaitu P10, P50, dan P90 untuk merepresentasikan interval ketidakpastian prediksi.

Konfigurasi utama model TFT yang digunakan dalam penelitian ini ditunjukkan pada Tabel 3.4.

Tabel 3.5 Konfigurasi Model Temporal Fusion Transformer

| Parameter         | Nilai         |
|-------------------|---------------|
| Encoder Length    | 90 hari       |
| Prediction Length | 30 hari       |
| Quantile Output   | P10, P50, P90 |
| Hidden Size       | 48            |
| Dropout           | 0,40          |
| Attention Heads   | 1             |

| Parameter         | Nilai  |
|-------------------|--------|
| Learning Rate     | 0,0003 |
| Weight Decay      | 0,0001 |
| Gradient Clipping | 0,5    |

Model TFT pada penelitian ini menggunakan pendekatan *quantile forecasting* dengan fungsi kerugian (*loss function*) berupa *Quantile Loss* atau *Pinball Loss*. Fungsi loss ini digunakan untuk melatih model agar mampu memprediksi distribusi probabilistik pada setiap kuantil target.

Persamaan *Quantile Loss* dinyatakan sebagai berikut:

$$L_q(y, \hat{y}_q) = \max(q(y - \hat{y}_q), (q - 1)(y - \hat{y}_q)) \quad (3.12)$$

dengan:

- $y$  = nilai aktual
- $\hat{y}_q$  = prediksi pada kuantil ke-  $q$
- $q$  = nilai kuantil

Penggunaan *Quantile Loss* memungkinkan model menghasilkan interval prediksi yang dapat digunakan untuk mengukur tingkat ketidakpastian hasil forecasting. Dalam penelitian ini, interval prediksi dibentuk menggunakan rentang antara kuantil P10 dan P90, sedangkan kuantil P50 digunakan sebagai prediksi median atau *point forecast*.

Selain kemampuan prediksi probabilistik, model TFT juga memiliki mekanisme *gating* dan *residual connection* yang membantu menjaga stabilitas proses pelatihan model. Mekanisme tersebut memungkinkan model memfilter informasi yang tidak relevan serta mengurangi risiko degradasi performa akibat kedalaman arsitektur jaringan.

Dengan kombinasi kemampuan *feature selection*, pemodelan temporal, mekanisme attention, dan probabilistic forecasting, arsitektur Temporal Fusion Transformer dinilai sesuai untuk digunakan dalam penelitian peramalan kekeringan berbasis SPEI-3 multi-horizon pada wilayah penelitian.

### 3.7 Pelatihan dan Validasi Model

Tahap pelatihan dan validasi model dilakukan untuk membangun model Temporal Fusion Transformer yang mampu mempelajari pola temporal kondisi kekeringan berdasarkan data historis serta menghasilkan prediksi multi-horizon yang stabil. Proses pelatihan dilakukan menggunakan dataset time series yang telah melalui tahap preprocessing, pembentukan super-node, dan feature engineering. Pada tahap ini, model mempelajari hubungan antara variabel hidroklimat historis dengan target prediksi berupa nilai SPEI-3 pada horizon waktu mendatang.

Pelatihan model dilakukan menggunakan pendekatan *supervised learning*, di mana model menerima sequence historis sebagai input dan target SPEI masa depan sebagai output yang harus diprediksi. Sequence historis sepanjang 90 hari digunakan sebagai encoder input, sedangkan model menghasilkan prediksi selama 30 hari ke depan secara simultan melalui mekanisme multi-horizon forecasting.

Dalam proses pelatihan, model dioptimasi menggunakan algoritma *Adam Optimizer* dengan learning rate sebesar 0,0003. Optimizer Adam dipilih karena memiliki kemampuan adaptif dalam memperbarui bobot model sehingga lebih stabil pada proses pelatihan jaringan saraf dalam (*deep neural network*). Selain itu, digunakan pula parameter *weight decay* untuk membantu mengurangi risiko overfitting selama proses training berlangsung.


Selama proses pelatihan, dilakukan pula mekanisme *early stopping* untuk mencegah overfitting dan menjaga stabilitas model. Early stopping bekerja dengan menghentikan proses training apabila performa model pada data validasi tidak menunjukkan peningkatan dalam sejumlah epoch tertentu. Pendekatan ini digunakan agar model tidak terlalu menyesuaikan diri terhadap data pelatihan sehingga tetap memiliki kemampuan generalisasi yang baik pada data baru.

Selain itu, digunakan pula teknik *gradient clipping* untuk menjaga stabilitas proses optimasi dan mencegah terjadinya exploding gradient pada pelatihan jaringan recurrent. Teknik ini dilakukan dengan membatasi nilai maksimum gradien selama proses backpropagation.

Proses pelatihan model dilakukan menggunakan mini-batch training dengan ukuran batch sebesar 32 sequence pada setiap iterasi. Penggunaan mini-batch

training bertujuan untuk meningkatkan efisiensi komputasi dan mempercepat proses konvergensi model selama pelatihan.

Tahap validasi dilakukan secara berkala menggunakan data validasi untuk memantau performa model selama proses training berlangsung. Evaluasi pada data validasi digunakan sebagai dasar pemilihan checkpoint model terbaik yang memiliki performa paling stabil terhadap data yang belum pernah dilihat selama pelatihan. Ilustrasi proses training dan validasi model dapat ditampilkan pada Gambar 3.5.



Gambar 3.6 Alur Proses Pelatihan

Selain validasi performa model, penelitian ini juga menerapkan beberapa strategi untuk menjaga integritas metodologi dan mencegah *data leakage*. Strategi tersebut meliputi:

1. penggunaan chronological split,
2. seleksi node hanya menggunakan data pelatihan,
3. penggunaan forward fill tanpa informasi masa depan,
4. pemisahan sequence berdasarkan super-node.

Pendekatan tersebut dilakukan agar hasil evaluasi model lebih merepresentasikan kondisi forecasting nyata pada data masa depan yang belum pernah diamati sebelumnya.

### 3.8 Peramalan Multi-Horizon

Setelah model Temporal Fusion Transformer selesai dilatih dan divalidasi, tahap berikutnya adalah proses peramalan multi-horizon terhadap nilai SPEI-3 pada periode mendatang. Tahap ini bertujuan untuk menghasilkan prediksi kondisi kekeringan hingga 30 hari ke depan secara simultan berdasarkan pola historis yang telah dipelajari model selama proses pelatihan. Pendekatan multi-horizon forecasting dipilih karena mampu memberikan informasi prediksi untuk beberapa langkah waktu sekaligus dalam satu proses inferensi, sehingga lebih efisien dan stabil dibandingkan pendekatan prediksi iteratif satu langkah (*single-step recursive forecasting*).

Pada penelitian ini, model menggunakan sequence historis sepanjang 90 hari sebagai input encoder dan menghasilkan prediksi SPEI-3 selama 30 hari mendatang sebagai output decoder. Dengan demikian, model tidak hanya memprediksi satu nilai masa depan, tetapi menghasilkan serangkaian prediksi pada berbagai horizon waktu secara simultan. Secara konseptual, proses multi-horizon forecasting dapat dinyatakan sebagai:

$$\hat{Y}_{t+1:t+30} = \{\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+30}\} \quad (3.13)$$

dengan:

- $\hat{y}_{t+1}$  = prediksi horizon 1 hari
- $\hat{y}_{t+2}$  = prediksi horizon 2 hari
- $\hat{y}_{t+30}$  = prediksi horizon 30 hari

Pendekatan multi-horizon memungkinkan model mempelajari hubungan temporal antar horizon secara langsung sehingga prediksi jangka pendek dan jangka menengah dapat dihasilkan dalam satu struktur pemodelan yang konsisten. Selain itu, pendekatan ini mengurangi akumulasi error yang umumnya terjadi pada metode forecasting iteratif, di mana hasil prediksi sebelumnya digunakan kembali sebagai input untuk prediksi berikutnya.

Pada proses inferensi, model menerima sequence historis berupa variabel hidroklimat, fitur temporal, dan target historis SPEI yang telah dibentuk pada tahap sebelumnya. Selanjutnya, model menghasilkan prediksi probabilistik berbasis kuantil yang terdiri atas:

1. P10 (*lower quantile*),
2. P50 (*median prediction*),
3. P90 (*upper quantile*).

Prediksi kuantil tersebut digunakan untuk merepresentasikan rentang ketidakpastian hasil forecasting. Dalam penelitian ini, kuantil P50 digunakan sebagai prediksi utama (*point forecast*), sedangkan interval antara P10 dan P90 digunakan sebagai estimasi rentang ketidakpastian kondisi kekeringan.

Interpretasi interval probabilistik tersebut menunjukkan bahwa nilai aktual diperkirakan berada di antara batas bawah (P10) dan batas atas (P90) dengan tingkat coverage tertentu. Dengan demikian, model tidak hanya memberikan satu estimasi nilai tunggal, tetapi juga memberikan gambaran tingkat keyakinan prediksi terhadap kondisi masa depan.

Pada penelitian ini, hasil prediksi digunakan dalam dua bentuk utama, yaitu:

1. *Point forecasting*,
2. *Uncertainty forecasting*.

Point forecasting menggunakan nilai median (P50) untuk mengevaluasi akurasi prediksi terhadap data aktual menggunakan metrik regresi seperti RMSE, MAE, dan koefisien determinasi ( $R^2$ ). Sementara itu, uncertainty forecasting menggunakan interval P10–P90 untuk mengevaluasi kemampuan model dalam merepresentasikan ketidakpastian prediksi menggunakan metrik Prediction Interval Coverage Probability (PICP).

Selain menghasilkan prediksi kondisi kekeringan harian, model juga digunakan untuk menganalisis perubahan tren SPEI pada setiap wilayah penelitian. Dengan adanya prediksi multi-horizon, model dapat memberikan gambaran mengenai potensi perubahan kondisi kering maupun basah dalam periode jangka pendek hingga menengah.

Tahap peramalan dilakukan secara independen untuk setiap super-node sehingga karakteristik temporal masing-masing wilayah tetap terjaga. Pendekatan

ini memungkinkan model mempelajari pola kekeringan spesifik pada setiap wilayah tanpa mencampurkan sequence antar kota. Selain itu, penggunaan super-node juga membantu menghasilkan prediksi yang lebih stabil karena data yang digunakan telah melalui proses agregasi spasial sebelumnya.

Dalam implementasinya, proses forecasting dilakukan menggunakan model terbaik hasil validasi yang diperoleh pada tahap pelatihan. Model tersebut kemudian digunakan untuk menghasilkan prediksi pada data pengujian yang berada pada periode setelah tahun 2024. Pendekatan ini bertujuan untuk memastikan bahwa evaluasi forecasting dilakukan pada data masa depan yang benar-benar belum pernah diamati model sebelumnya.

### 3.9 Evaluasi Model

Tahap evaluasi model dilakukan untuk mengukur kemampuan Temporal Fusion Transformer dalam memprediksi kondisi kekeringan berbasis indeks SPEI-3 pada berbagai horizon waktu. Evaluasi dilakukan terhadap hasil prediksi pada data pengujian yang berada di luar periode pelatihan sehingga performa model dapat merepresentasikan kemampuan forecasting pada data masa depan yang belum pernah diamati sebelumnya. Selain untuk mengukur akurasi prediksi, tahap evaluasi juga bertujuan untuk menilai stabilitas model, kemampuan representasi ketidakpastian, serta membandingkan performa model terhadap pendekatan baseline sederhana.

Tabel 3.6 Skenario Evaluasi

| Skenario Pengujian               | Data atau Periode Uji              | Parameter atau Output yang Diamati                 | Metrik Evaluasi                             | Hasil Pengujian |
|----------------------------------|------------------------------------|----------------------------------------------------|---------------------------------------------|-----------------|
| Evaluasi point forecast agregat  | Data uji tahun 2024 dan setelahnya | Prediksi median P50 SPEI-3 seluruh data uji        | RMSE, MAE, $R^2$ , Pearson r                | -               |
| Evaluasi point forecast per kota | Data uji tahun 2024 dan setelahnya | Prediksi median P50 SPEI-3 untuk setiap super-node | RMSE, MAE, $R^2$ , Pearson r per super-node | -               |



| <b>Skenario Pengujian</b>       | <b>Data atau Periode Uji</b>                   | <b>Parameter atau Output yang Diamati</b>                         | <b>Metrik Evaluasi</b>                         | <b>Hasil Pengujian</b> |
|---------------------------------|------------------------------------------------|-------------------------------------------------------------------|------------------------------------------------|------------------------|
| Evaluasi probabilistik agregat  | Data uji tahun 2024 dan setelahnya             | Interval prediksi P10-P90 seluruh data uji                        | PICP, nominal coverage 80%                     | -                      |
| Evaluasi probabilistik per kota | Data uji tahun 2024 dan setelahnya             | Interval prediksi P10-P90 setiap super-node                       | PICP per super-node                            | -                      |
| Perbandingan baseline           | Data uji tahun 2024 dan setelahnya             | Prediksi P50 TFT dan prediksi naive persistence                   | RMSE, MAE, kemenangan per horizon              | -                      |
| Evaluasi antar-horizon          | Data uji tahun 2024 dan setelahnya             | Prediksi P50 pada horizon hari ke-1 hingga ke-30                  | RMSE dan MAE per horizon 1–30 hari             | -                      |
| Evaluasi kalibrasi per kota     | Validasi 2023 dan data uji 2024 dan setelahnya | Interval P10-P90 sebelum serta setelah kalibrasi per kota         | PICP sebelum dan sesudah kalibrasi             | -                      |
| Analisis interpretabilitas      | Data uji tahun 2024 dan setelahnya             | Bobot Variable Selection Network serta temporal attention weights | Peringkat fitur dan temporal attention weights | -                      |

Tabel 3.5 menyajikan skenario pengujian yang direncanakan untuk mengevaluasi model TFT secara menyeluruh. Kolom hasil pengujian nilainya diperoleh setelah pelatihan, peramalan, dan evaluasi model dilaksanakan. Skenario tersebut mencakup evaluasi prediksi titik dan probabilistik, perbandingan dengan naive persistence baseline, degradasi performa antar-horizon, kalibrasi interval per kota, serta interpretabilitas model.

Evaluasi model pada penelitian ini dilakukan menggunakan beberapa metrik regresi dan metrik probabilistik. Penggunaan beberapa metrik secara bersamaan dilakukan karena setiap metrik memiliki karakteristik evaluasi yang berbeda dalam

menilai kualitas hasil forecasting. Selain itu, evaluasi dilakukan baik secara agregat maupun per wilayah penelitian untuk melihat konsistensi performa model pada masing-masing super-node.

Tahap evaluasi pertama dilakukan menggunakan Root Mean Squared Error (RMSE). RMSE digunakan untuk mengukur rata-rata kesalahan prediksi dengan memberikan penalti lebih besar terhadap error yang bernilai tinggi. Dengan demikian, metrik ini sensitif terhadap prediksi yang memiliki deviasi besar dari nilai aktual. Perhitungan RMSE dinyatakan sebagai:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.14)$$

dengan:

- $y_i$  = nilai aktual
- $\hat{y}_i$  = nilai prediksi
- $n$  = jumlah data pengamatan

Semakin kecil nilai RMSE, maka performa model dalam memprediksi nilai SPEI semakin baik.

Selain RMSE, digunakan pula Mean Absolute Error (MAE) untuk mengukur rata-rata kesalahan absolut antara nilai aktual dan prediksi. Berbeda dengan RMSE, MAE tidak memberikan penalti kuadrat terhadap error besar sehingga lebih stabil terhadap outlier. Perhitungan MAE dinyatakan sebagai:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.15)$$

dengan:

- $y_i$  = nilai aktual
- $\hat{y}_i$  = nilai prediksi
- $n$  = jumlah data pengamatan

Metrik berikutnya adalah koefisien determinasi ( $R^2$ ) yang digunakan untuk mengukur kemampuan model dalam menjelaskan variasi data aktual. Nilai  $R^2$  yang mendekati 1 menunjukkan bahwa model mampu merepresentasikan pola data dengan baik. Koefisien determinasi dinyatakan sebagai:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (3.16)$$

dengan:

- $y_i$  = nilai aktual
- $\hat{y}_i$  = nilai prediksi
- $\bar{y}$  = rata-rata nilai aktual

Selain ketiga metrik utama tersebut, penelitian ini juga menggunakan korelasi Pearson (*Pearson correlation coefficient*) untuk mengukur kekuatan hubungan linear antara hasil prediksi dan data aktual. Nilai korelasi yang tinggi menunjukkan bahwa model mampu mengikuti pola perubahan temporal SPEI secara konsisten. Persamaan korelasi Pearson dinyatakan sebagai:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (3.17)$$

dengan:

- $r$  = koefisien korelasi Pearson
- $x_i$  = data aktual
- $y_i$  = data prediksi

Selain evaluasi point forecast, penelitian ini juga melakukan evaluasi terhadap kemampuan model dalam merepresentasikan ketidakpastian prediksi menggunakan Prediction Interval Coverage Probability (PICP). Metrik ini digunakan untuk mengukur persentase data aktual yang berada di dalam interval prediksi probabilistik antara kuantil P10 dan P90. Perhitungan PICP dinyatakan sebagai:

$$PICP = \frac{1}{n} \sum_{i=1}^n I(y_i \in [P10_i, P90_i]) \quad (3.18)$$

dengan:

- $I(\cdot)$  = fungsi indikator
- $P10_i$  = batas bawah interval prediksi
- $P90_i$  = batas atas interval prediksi

Pada penelitian ini, interval P10–P90 merepresentasikan nominal coverage sebesar 80%. Semakin mendekati nilai tersebut, maka interval prediksi model dianggap semakin baik dalam merepresentasikan ketidakpastian forecasting.

Selain evaluasi terhadap model utama, penelitian ini juga menggunakan pendekatan *naive persistence baseline* sebagai pembanding performa forecasting. Baseline persistence merupakan metode sederhana yang mengasumsikan bahwa kondisi pada waktu mendatang akan sama dengan kondisi terakhir yang diamati. Penggunaan baseline ini bertujuan untuk memastikan bahwa model TFT benar-benar memberikan peningkatan performa dibandingkan pendekatan forecasting sederhana. Secara konseptual, naive persistence dapat dinyatakan sebagai:

$$\hat{y}_{t+h} = y_t \quad (3.19)$$

dengan:

- $\hat{y}_{t+h}$  = prediksi pada horizon ke-hhh
- $y_t$  = nilai observasi terakhir

Jika performa model TFT lebih baik dibanding baseline persistence pada sebagian besar horizon prediksi, maka model dapat dianggap berhasil mempelajari pola temporal yang lebih kompleks dibandingkan sekadar mempertahankan nilai sebelumnya.

Evaluasi model dilakukan baik secara agregat maupun secara individual pada masing-masing wilayah penelitian. Evaluasi per wilayah dilakukan untuk mengetahui konsistensi performa model terhadap karakteristik spasial yang berbeda antar super-node. Pendekatan ini penting karena kondisi hidroklimat pada setiap wilayah penelitian dapat memiliki pola musiman dan tingkat variabilitas yang berbeda.

Selain evaluasi numerik, penelitian ini juga melakukan analisis visual terhadap hasil forecasting menggunakan grafik perbandingan antara nilai aktual dan prediksi. Visualisasi tersebut digunakan untuk mengamati kemampuan model dalam mengikuti pola temporal SPEI serta mendeteksi potensi underfitting maupun overfitting pada horizon tertentu.

Tahap evaluasi model menghasilkan informasi mengenai tingkat akurasi, stabilitas, dan kemampuan representasi ketidakpastian model Temporal Fusion Transformer dalam melakukan forecasting kekeringan multi-horizon. Hasil evaluasi tersebut selanjutnya digunakan sebagai dasar analisis interpretabilitas model dan pembahasan performa forecasting pada bab berikutnya.

### 3.10 Analisis Interpretabilitas Model

Selain menghasilkan prediksi multi-horizon, penelitian ini juga melakukan analisis interpretabilitas terhadap model Temporal Fusion Transformer untuk memahami kontribusi variabel input dan pola temporal yang memengaruhi hasil forecasting SPEI-3. Analisis interpretabilitas dilakukan karena model *deep learning* umumnya bersifat *black box*, yaitu menghasilkan prediksi yang sulit dijelaskan secara langsung. Dalam konteks penelitian hidrometeorologi dan kekeringan, kemampuan interpretasi model menjadi penting agar hasil prediksi tidak hanya memiliki akurasi tinggi, tetapi juga dapat dipahami secara ilmiah.

Temporal Fusion Transformer memiliki mekanisme interpretabilitas bawaan (*built-in interpretability*) melalui beberapa komponen utama, yaitu:

1. *Variable Selection Network* (VSN),
2. *Attention Mechanism*,
3. *Temporal Attention Weights*.

Melalui komponen tersebut, model dapat menunjukkan variabel mana yang paling berpengaruh terhadap prediksi serta bagian sequence historis mana yang memperoleh perhatian terbesar selama proses forecasting.

Tahap interpretabilitas pertama dilakukan menggunakan *Variable Selection Network* (VSN). Mekanisme ini bekerja dengan memberikan bobot terhadap setiap fitur input berdasarkan tingkat relevansinya terhadap target prediksi. Dengan demikian, model dapat memilih variabel yang dianggap paling penting secara adaptif pada setiap langkah waktu.

Selain analisis kontribusi variabel, interpretabilitas juga dilakukan menggunakan mekanisme *temporal attention*. Attention mechanism pada TFT memungkinkan model memberikan fokus lebih besar terhadap bagian sequence historis tertentu yang dianggap penting dalam proses forecasting. Dengan demikian, model dapat menunjukkan periode waktu historis mana yang paling memengaruhi prediksi SPEI pada horizon tertentu.

Melalui attention weights, model dapat menunjukkan hubungan temporal antara kondisi historis dan hasil prediksi masa depan. Informasi tersebut dapat digunakan untuk memahami pola musiman, periode anomali iklim, maupun pengaruh kondisi hidroklimat tertentu terhadap perkembangan kekeringan.

Analisis interpretabilitas pada penelitian ini dilakukan secara deskriptif dan eksploratif tanpa bertujuan untuk membangun hubungan kausal antar variabel. Dengan kata lain, hasil interpretasi digunakan untuk memahami pola kontribusi variabel berdasarkan pembelajaran model, bukan untuk menyimpulkan hubungan sebab-akibat secara langsung. Pendekatan ini penting untuk menjaga validitas metodologis karena model deep learning pada dasarnya mempelajari pola statistik dari data historis.

Selain itu, interpretabilitas model juga digunakan untuk mendukung analisis performa forecasting pada masing-masing wilayah penelitian. Perbedaan kontribusi variabel antar wilayah dapat memberikan indikasi adanya karakteristik hidroklimat lokal yang berbeda pada setiap super-node. Dengan demikian, interpretasi model tidak hanya membantu memahami proses prediksi, tetapi juga memberikan wawasan tambahan mengenai dinamika kekeringan pada wilayah penelitian.


Pada tahap implementasi, hasil interpretabilitas divisualisasikan dalam bentuk grafik *feature importance* dan *attention heatmap*. Visualisasi tersebut digunakan untuk mempermudah analisis terhadap pola perhatian model selama proses forecasting multi-horizon.

Melalui analisis interpretabilitas ini, penelitian tidak hanya berfokus pada peningkatan akurasi prediksi, tetapi juga berupaya memberikan pemahaman mengenai pola temporal dan variabel hidroklimat yang berperan dalam proses forecasting kekeringan. Dengan demikian, model Temporal Fusion Transformer yang digunakan tidak hanya bersifat prediktif, tetapi juga memberikan kemampuan interpretatif yang mendukung analisis kondisi kekeringan secara lebih komprehensif.

### **3.11 Perancangan Web Visualisasi Hasil Peramalan**

Tahap perancangan web visualisasi hasil dilakukan untuk menyajikan keluaran model peramalan dalam bentuk yang mudah dipahami oleh pengguna. Dashboard dirancang sebagai lapisan penyajian yang menampilkan hasil inferensi model, bukan sebagai komponen yang melakukan pelatihan ulang model. Dengan batasan tersebut, nilai prediksi dan metrik yang ditampilkan tetap berasal dari artefak hasil pipeline peramalan dan evaluasi, sehingga konsistensi antara hasil analitik dan informasi pada dashboard dapat dijaga.

Arsitektur web dirancang menggunakan Vue.js pada sisi antarmuka pengguna dan FastAPI pada sisi layanan. Vue.js digunakan untuk membangun komponen visual seperti pemilih wilayah, ringkasan status SPEI-3, grafik prediksi multi-horizon, interval P10-P90, tabel evaluasi, serta visualisasi interpretabilitas. FastAPI digunakan untuk menyediakan endpoint berbasis JSON yang menyalurkan data prediksi, metrik evaluasi, kategori kekeringan, dan informasi kontribusi variabel dari artefak hasil model. Pemisahan ini memungkinkan pengembangan antarmuka dilakukan secara modular tanpa mengubah proses pengolahan data atau inferensi model [34], [35].



Gambar 3.7 Mockup Web Visualisasi

Gambar 3.4 menunjukkan mockup rancangan dashboard visualisasi hasil peramalan SPEI-3. Rancangan antarmuka memuat area pemilihan kota dan periode pengamatan, ringkasan kondisi kekeringan, grafik deret waktu yang membandingkan nilai aktual dengan prediksi P50, serta rentang ketidakpastian P10-P90. Dashboard juga dirancang untuk menyediakan tabel atau kartu ringkasan metrik evaluasi dan visualisasi interpretabilitas agar pengguna dapat memahami kualitas prediksi serta variabel yang paling berpengaruh.

Pada tahap implementasi, alur akses data dimulai dari permintaan pengguna pada antarmuka Vue.js. Permintaan tersebut diteruskan ke endpoint FastAPI untuk mengambil artefak prediksi dan evaluasi yang telah tersedia. Respons API kemudian divisualisasikan secara reaktif oleh Vue.js. Rancangan ini

mendukung pemantauan kondisi SPEI-3 per wilayah dan horizon prediksi, sekaligus menjaga pemisahan antara proses komputasi model dengan proses penyajian informasi pada dashboard.



## DAFTAR PUSTAKA

- [1] E. Hunt *et al.*, “Agricultural and food security impacts from the 2010 Russia flash drought,” *Weather Clim. Extrem.*, vol. 34, no. September 2020, p. 100383, 2021, doi: 10.1016/j.wace.2021.100383.
- [2] W. Kim, T. Iizumi, and M. Nishimori, “Global Patterns of Crop Production Losses Associated with Droughts from 1983 to 2009,” pp. 1233–1244, 2019, doi: 10.1175/JAMC-D-18-0174.1.
- [3] G. Leng and J. Hall, “Crop yield sensitivity of global major agricultural countries to droughts and the projected changes in the future,” *Sci. Total Environ.*, vol. 654, pp. 811–821, 2019, doi: 10.1016/j.scitotenv.2018.10.434.
- [4] I. R. Orimoloye, “Agricultural Drought and Its Potential Impacts : Enabling Decision-Support for Food Security in Vulnerable Regions,” vol. 6, no. February, 2022, doi: 10.3389/fsufs.2022.838824.
- [5] D. Zhang, R. Glaser, and M. Kahle, “Stable yet dynamic : a cross-era comparative case study of drought impacts and social responses in Germany and Jing-Jin-Ji Region ( China ),” pp. 1481–1500, 2025, doi: 10.5194/cp-21-1481-2025.
- [6] M. Z. Getaneh, V. G. Jetten, J. Ettema, and D. T. Meshesha, “Spatio-temporal characteristics of drought and its impact on local food security : the case of Libokemkem and Ebinat district, Northwestern Ethiopia,” pp. 19993–20020, 2025.
- [7] P. Roy, S. C. Pal, R. Chakraborty, I. Chowdhuri, A. Saha, and M. Shit, “Climate change and groundwater overdraft impacts on agricultural drought in India: Vulnerability assessment, food security measures and policy recommendation,” *Sci. Total Environ.*, 2022, doi: 10.1016/j.scitotenv.2022.157850.
- [8] Y. Lu, T. Yang, J. Fu, and W. Song, “Journal of Hydrology : Regional Studies Utility of the standardized precipitation evapotranspiration index ( SPEI ) to detect agricultural droughts over China,” *J. Hydrol. Reg. Stud.*, vol. 58, no. January, p. 102190, 2025, doi: 10.1016/j.ejrh.2025.102190.
- [9] A. Rassoul, Z. Mohammad, and R. Mahmoudi, “Determining the most

- appropriate drought index using the random forest algorithm with an emphasis on agricultural drought,” *Nat. Hazards*, no. 0123456789, 2022, doi: 10.1007/s11069-022-05579-2.
- [10] G. Sosa, M. E. Fernández-Long, and S. M. Vicente-Serrano, “Evaluating the performance of drought indices for assessing agricultural droughts in Argentina,” no. December 2024, pp. 1–15, 2025, doi: 10.1002/agj2.70008.
  - [11] M. M. Mliyah *et al.*, “Multi-Index Approach to Assess and Monitor Meteorological and Agricultural Drought in the Mediterranean Region : Case of the Upper Oum Er Rabia Watershed , Morocco,” 2024.
  - [12] D. Xu, Q. Zhang, Y. Ding, and D. Zhang, “Application of a hybrid ARIMA-LSTM model based on the SPEI for drought forecasting,” 2021, doi: 10.1007/s11356-021-15325-z.
  - [13] M. Carrillo-carrillo, L. Ibáñez-castillo, and R. Arteaga-ramírez, “SPEI Drought Forecasting in Central Mexico,” pp. 1–20, 2025.
  - [14] F. Zeng *et al.*, “Modeling Short-Term Drought for SPEI in Mainland China Using the XGBoost Model,” 2025.
  - [15] A. Dikshit, B. Pradhan, and A. Huete, “An improved SPEI drought forecasting approach using the long short-term memory neural network,” *J. Environ. Manage.*, vol. 283, no. January, p. 111979, 2021, doi: 10.1016/j.jenvman.2021.111979.
  - [16] D. N. Q. Hoa, P. Q. Nam, and P. Van Tan, “Drought prediction across Vietnam using a hybrid approach,” *Vietnam J. Earth Sci.*, 2025, doi: 10.15625/2615-9783/22194.
  - [17] J. Shang, B. Zhao, H. Hua, J. Wei, G. Qin, and G. Chen, “Application of Informer Model Based on SPEI for Drought Forecasting,” pp. 1–20, 2023, doi: 10.3390/atmos14060951.
  - [18] A. D. Mehr, A. R. Ghiasi, Z. M. Yaseen, A. U. Sorman, and L. Abualigah, “A novel intelligent deep learning predictive model for meteorological drought forecasting,” *J. Ambient Intell. Humaniz. Comput.*, vol. 14, no. 8, pp. 10441–10455, 2023, doi: 10.1007/s12652-022-03701-7.
  - [19] J. Liu, T. Liu, L. Huang, Y. Ren, and P. He, “Next-Generation Drought Forecasting : Hybrid AI Models for Climate Resilience,” pp. 1–32, 2025.

- [20] A. D. Mehr, A. A. Ghavifekr, E. Ghazaei, M. J. S. Safari, C. Ke, and V. Nourani, "S-Transformer : a new deep learning model enhanced by sequential transformer encoders for drought forecasting," *Earth Sci. Informatics*, 2025, doi: 10.1007/s12145-025-01845-6.
- [21] I. Tanriverdi and İ. Batmaz, "AI - driven U . S . drought prediction using machine learning and deep learning," 2025, doi: 10.1007/s00382-025-07720-w.
- [22] A. Gyaneshwar *et al.*, "A Contemporary Review on Deep Learning Models for Drought Prediction," pp. 1–31, 2023, doi: 10.3390/ su15076160.
- [23] R. Sadrtidnova, G. A. C. Perez, and D. P. Solomatine, "Improved drought forecasting in Kazakhstan using machine and deep learning : a non-contiguous drought analysis approach a," *Hydrol. Res.*, vol. 55, no. 2, pp. 237–261, 2024, doi: 10.2166/nh.2024.154.
- [24] B. Lim, S. Ö. Arık, N. Loeff, and T. Pfister, "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting," *Int. J. Forecast.*, vol. 37, no. 4, pp. 1748–1764, 2021, doi: 10.1016/j.ijforecast.2021.03.012.
- [25] B. Solaraju-murali *et al.*, "Multi-annual prediction of drought and heat stress to support decision making in the wheat sector," *npj Clim. Atmos. Sci.*, 2021, doi: 10.1038/s41612-021-00189-4.
- [26] A. Barzkar, M. Najafzadeh, and F. Homaei, "Evaluation of drought events in various climatic conditions using data - driven models and a reliability - based probabilistic model," *Nat. Hazards*, vol. 110, no. 3, pp. 1931–1952, 2022, doi: 10.1007/s11069-021-05019-7.
- [27] Z. Eslami, A. Shirvani, and F. Granata, "Unlocking the Potential of Dynamical Models for Drought Forecasting in Iran : Insights From Multi- - Model Ensemble Analysis," 2025, doi: 10.1002/met.70082.
- [28] M. Karbasi, M. Jamei, A. Malik, O. Kisi, and Z. Mundher, "Multi-steps drought forecasting in arid and humid climate environments : Development of integrative machine learning model," *Agric. Water Manag.*, vol. 281, no. January, p. 108210, 2023, doi: 10.1016/j.agwat.2023.108210.
- [29] M. Karbasi, M. Karbasi, M. Jamei, A. Malik, and H. Mohammad,

- “Development of a new wavelet - based hybrid model to forecast multi - scalar SPEI drought index ( case study : Zanzan city , Iran ),” *Theor. Appl. Climatol.*, pp. 499–522, 2022, doi: 10.1007/s00704-021-03825-4.
- [30] J. Shen, P. Qin, and R. Zhong, “Optimization of Temporal Feature Attribution and Sequential Dependency Modeling for High-Precision Multi-Step Resource Forecasting : A Methodological Framework and Empirical Evaluation,” pp. 1–19, 2025.
- [31] H. Saleh, S. El-sappagh, M. Mccann, S. Hamood, and J. G. Breslin, “Multivariate multi-horizon time-series forecasting for real-time patient monitoring based on cascaded fine tuning of attention-based models,” *Comput. Biol. Med.*, vol. 194, no. May, p. 110406, 2025, doi: 10.1016/j.compbimed.2025.110406.
- [32] F. Karim, A. Fahmi, C. N. Ratnasari, and A. Seftiarini, “Forecasting and Mapping of Vulnerable Areas Floods and Droughts in Rice Crops Impacts of Climate Change In 2022 in East Java Province,” vol. 2023, pp. 8–18, 2023.
- [33] A. Faisol, I. Indarto, E. Novita, and B. Budiyo, “Assessment of agricultural drought based on CHIRPS data and SPI method over West Papua – Indonesia,” 2022, doi: 10.24425/jwld.2021.139942.
- [34] F. A. F. Sofi’ie and A. Qoiriah, “Analisis Perbandingan Framework Front-End Javascript React dan Vue Pada Pengembangan Website Analisis Kebutuhan Pembuatan Sistem Pengumpulan Data Analisa Data,” vol. 05, pp. 157–164, 2023.
- [35] J. Chen, “Application Technology of Atmospheric Dispersion Models Based on FastAPI + Vue,” vol. 6, no. 11, pp. 120–126, 2023, doi: 10.25236/AJETS.2023.061118.